Trois nouvelles architectures neuronales pour la stabilite lineaire d'un ecoulement de Taylor–Couette oscillatoire en fluide de Maxwell convecte superieur : meta-apprentissage, distillation d'ensemble et raffineur RL augmente

Mohamed Hayani Choujaa*[1]

[1]Laboratoire de Mecanique, Faculte des Sciences Ain Chock, Universite Hassan II de Casablanca, Maroc

15 mai 2026

Resume. Predire la courbe de stabilite marginale $T_a(k)$ d'un ecoulement de Taylor–Couette oscillatoire en fluide de Maxwell convecte superieur (UCM) avec cylindres oscillant en opposition de phase est un probleme couteux : chaque point de la courbe requiert la diagonalisation d'un operateur de Floquet sur la periode d'oscillation. Le jeu de donnees produit dans Hayani Choujaa *et al.* [1] comporte $N = 720$ branches dans le plan (k, E) pour $E \in [10^{-4}, 10]$, $k \in [k_{\text{left}}, k_{\text{right}}]$, chacune associee a 23 descripteurs functionnels. Apres une premiere generation de neuf surrogates supervises publiee dans la v1 du projet TaylorCouetteML [2], nous proposons ici trois nouvelles architectures qui adressent trois faiblesses identifiees : (i) un *Conditional Neural Process* (**CNP-TC**) qui exploite 0 a 32 points exacts (k_c, T_{ac}) comme contexte additionnel a l'inference ; (ii) une distillation single-model (**DISTIL-STAR**) reproduisant la mediane de 29 surrogates dans un unique forward pass 30× plus rapide ; (iii) un raffineur RL ensemble re-agrege en *weighted-SARL* puis fusionne avec la mediane d'ensemble (**RL-aug**) couvrant toute la branche $[k_{\text{left}}, k_{\text{right}}]$. La MAE physique sur le split test passe de 1,21 pour la mediane d'ensemble **MED-NN** (etat de l'art v1) a 1,11 pour **RL-aug** dans la zone du switch, soit un gain de 8%, avec un $R^2 global de 0{,}9997 sur T_a \in [60, 560]$. *La distillation* ***DISTIL-STAR*** *preserve* 96% *de la performance ensemble en divisant le cout d'inference par* ~ 30. *L'inference few-shot du* ***CNP-TC*** *diminue la MAE d'un facteur* 3 *a partir de 4 points exacts par branche.*

1 Introduction et motivation

1.1 Probleme physique et motivation industrielle

L'instabilite des ecoulements viscoelastiques en geometrie courbe est un sujet recurrent en mecanique des fluides non-newtoniens [3, 4]. Le cas modele canonique est celui de *Taylor–Couette* : un fluide est confine entre deux cylindres coaxiaux et la deformation azimutale du fluide est imposee par la rotation differentielle des deux parois. Lorsque le fluide est viscoelastique, par exemple un fluide de Maxwell convecte superieur (UCM), les contraintes normales elastiques generent une force centripete additionnelle qui *deplace le seuil d'instabilite* par rapport au cas newtonien et peut induire des branches d'instabilite secondaires absentes du cas inelastique [3].

L'interet industriel de ces ecoulements est triple :

— En *extrusion polymerique*, le passage du fluide entre parois oscillantes est exactement la configuration de notre etude ; identifier la frontiere de stabilite permet de prevenir les defauts de surface (*melt fracture*).

*hayani.med11@gmail.com

— En *microfluidique viscoelastique*, le controle precis de la transition vers la turbulence elastique est utilise pour intensifier le melange a tres bas Reynolds.

— En *rheometrie*, l'apparition de motifs Taylor signe experimentalement les proprietes elastiques du fluide ; un surrogate predictif tres rapide permet de *calibrer en ligne* le rheometre.

1.2 Cout du solveur direct et necessite d'un surrogate

Le calcul direct d'un point (k, E, T_a) de la courbe marginale requiert :

1. L'integration de Floquet de l'equation aux derivees partielles linearisee autour de l'etat de base oscillant, sur une periode T d'oscillation, pour chaque nombre d'onde axial k ;
2. La construction de la matrice de monodromie $\Phi(T)$;
3. La recherche du T_a critique tel que la plus grande valeur propre de $\Phi(T)$ traverse le cercle unite.

Pour une discretisation realiste (50 modes radiaux, 100 pas de temps), le cout est de l'ordre de ~ 50 secondes par point (k, T_a) sur un CPU haute frequence. Une seule branche complete (~ 150 points) coute donc plus de deux heures, et l'exploration complete a 720 branches consommerait ~ 1500 heures-CPU. Un surrogate neural qui ramene chaque branche a < 1 seconde fournit un gain de *trois ordres de grandeur* indispensable a toute exploration parametrique ou a une utilisation en boucle de controle.

1.3 Limites de la v1 et apport de la v2

Le cadre TaylorCouetteML v1 [2] a livre neuf architectures (SSST, NEPTUNE, SARL, MARL, HYDRA, SIREN, DeepONet, Chebyshev, Envelope-SIREN) sur le meme jeu de 720 branches. Le benchmark final v1 atteint MAE $= 0{,}018$ et $R^2 = 0{,}986$ pour le meilleur raffineur MARL.

Deux faiblesses subsistent :

— **Faiblesse aux extremes en E.** Pour $E \in \{10^{-4}, 10\}$, les surrogates individuels ne disposent d'aucun point exact ponctuel pour calibrer leur sortie. Le physicien souhaiterait pouvoir, optionnellement, fournir quelques mesures de reference sans reentrainer le modele.

— **Cout de servir l'ensemble.** La mediane des 29 modeles est l'etat de l'art, mais l'inference en production reste 29 fois plus chere qu'un seul forward.

La v2 introduit trois architectures qui ciblent ces limites :

1. **CNP-TC** (Section 4) : un Conditional Neural Process qui supporte des contextes few-shot (k_c, T_{ac}) variables ;
2. **DISTIL-STAR** (Section 5) : un etudiant unique reproduisant la mediane des 29 teachers ;
3. **RL-aug** (Section 6) : un raffineur RL ensemble re-agrege en *weighted-SARL* et augmente d'une couverture complete par fusion avec **MED-NN** en dehors de la fenetre du switch.

La Section 2 pose la formulation mathematique du probleme physique ; la Section 3 decrit la construction du jeu de donnees ; les Sections 4–6 detaillent les trois architectures ; la Section 7 specifie le protocole experimental et la Section 8 les resultats. La Section 9 discute le choix technique du *maintien de la base D5* (et non MED-NN) pour le RL refiner, puis la Section 10 conclut.

2 Formulation mathematique du probleme physique

2.1 Equations gouvernantes

On considere un fluide incompressible de Maxwell convecte superieur (UCM) confine entre deux cylindres coaxiaux de rayons $R_1 < R_2$, hauteur infinie, tournant a vitesses azimutales $\Omega_1(t)$ et $\Omega_2(t)$ harmoniques de meme pulsation ω et en *opposition de phase* :

$$\Omega_1(t) = \Omega_0 \cos(\omega t), \qquad \Omega_2(t) = -\Omega_0 \cos(\omega t). \tag{1}$$

Le champ de vitesse $\mathbf{u}(r, \theta, z, t)$ et le tenseur des contraintes elastiques $\boldsymbol{\tau}$ verifient le systeme adimensionnel

$$\nabla \cdot \mathbf{u} = 0, \tag{2}$$

$$Re\,(\partial_t \mathbf{u} + \mathbf{u}\cdot\nabla\mathbf{u}) = -\nabla p + (1-\beta)\,\nabla^2\mathbf{u} + \nabla\cdot\boldsymbol{\tau}, \tag{3}$$

$$\boldsymbol{\tau} + We\,\overset{\nabla}{\boldsymbol{\tau}} = 2\beta\,\mathbf{D}, \tag{4}$$

ou $\mathbf{D} = \frac{1}{2}(\nabla\mathbf{u} + \nabla\mathbf{u}^\top)$ est le taux de deformation et $\overset{\nabla}{\boldsymbol{\tau}} = \partial_t\boldsymbol{\tau} + \mathbf{u}\cdot\nabla\boldsymbol{\tau} - (\nabla\mathbf{u})^\top\boldsymbol{\tau} - \boldsymbol{\tau}(\nabla\mathbf{u})$ la derivee de Maxwell convectee superieure. Le ratio $\beta = \eta_p/\eta_0$ $(0 \le \beta \le 1)$ fixe la contribution polymerique, $Re = \rho\Omega_0 R_1^2/\eta_0$ le nombre de Reynolds et $We = \Omega_0\lambda$ le nombre de Weissenberg, λ etant le temps de relaxation du polymere. On se place ici en regime $\beta = 1$ (UCM pur).

2.2 Etat de base et linearisation

L'etat de base axisymetrique invariant par translation axiale $(\mathbf{U}_0, \boldsymbol{\tau}_0)$ est obtenu en cherchant $\mathbf{U}_0(r,t) = U_\theta(r,t)\,\hat{\boldsymbol{\theta}}$ avec $U_\theta(r,t) = \mathrm{Re}\big[\hat{U}(r)\,e^{i\omega t}\big]$. Les equations (2)–(4) admettent alors une solution exprimable en fonctions de Bessel modifiees [1].

Les perturbations infinitesimales sont decomposees en modes (k, n) :

$$(\mathbf{u}', \boldsymbol{\tau}', p')(r, \theta, z, t) = (\widetilde{\mathbf{u}}, \widetilde{\boldsymbol{\tau}}, \widetilde{p})(r, t)\,e^{i(kz+n\theta)}. \tag{5}$$

Pour le mode azimutal axisymetrique $n = 0$, on obtient un systeme lineaire periodique de periode $T = 2\pi/\omega$ en la variable $r \in [1, \eta^{-1}]$ $(\eta = R_1/R_2)$, de la forme

$$\partial_t \mathbf{X}(r,t) \;=\; \mathcal{L}(r, t, k, Re, We, T_a)\,\mathbf{X}(r,t), \tag{6}$$

ou $\mathbf{X} = (\widetilde{u}_r, \widetilde{u}_\theta, \widetilde{u}_z, \widetilde{\tau}_{rr}, \dots)^\top$ est le vecteur d'etat des perturbations et $\mathcal{L}$ depend periodiquement du temps.

Le nombre de Taylor T_a definit l'amplitude du forcing : $T_a = \Omega_0^2 R_1 (R_2 - R_1)^3/\nu^2$ (avec $\nu = \eta_0/\rho$).

2.3 Theorie de Floquet et courbe marginale

L'equation (6) etant lineaire et periodique en temps, sa solution sur une periode est de la forme $\mathbf{X}(r,T) = \Phi(T; k, T_a)\,\mathbf{X}(r,0)$, ou $\Phi(T)$ est la *matrice de monodromie de Floquet*. Les valeurs propres σ_j de $\Phi(T)$ (multiplicateurs de Floquet) gouvernent la stabilite asymptotique des perturbations :

$$\max_j |\sigma_j| \;<\; 1 \Leftrightarrow \text{stable}, \qquad \max_j |\sigma_j| \;>\; 1 \Leftrightarrow \text{instable}. \tag{7}$$

La *courbe marginale* dans le plan (k, T_a) est definie implicitement par

$$\boxed{\mathcal{F}(k, T_a; We) \;:=\; \max_j |\sigma_j(\Phi(T; k, T_a))| \;-\; 1 \;=\; 0.} \tag{8}$$

Pour *We* fixe, on definit la fonction $T_a : k \mapsto T_{ac}(k; We)$ comme l'inverse implicite de (8) : $T_{ac}(k)$ est le nombre de Taylor critique qui rend la perturbation de longueur d'onde axiale $2\pi/k$ marginalement stable. C'est cette fonction $k \mapsto T_a(k, E)$ (avec $E = We^2/Re$ le nombre d'elasticite [3]) que nos surrogates approximent.

2.4 Topologie de $T_a(k)$ et notion de branche

Pour *We* croissant, la solution implicite (8) possede plusieurs branches dans le plan (k, T_a) : chaque branche correspond a un mode de Floquet different qui devient le mode le plus instable a un certain intervalle de k. Les transitions entre branches sont des *cusps* (points C^0 mais non C^1) en k. Le nombre de branches dans l'intervalle $k \in [1, 20]$ varie typiquement de 1 (a faible elasticite) a $n_b \in \{4, 5\}$ (a haute elasticite). Notre jeu de donnees regroupe chaque branche isolement : une branche est un triplet $(E, b_{\text{local}}, \{(k_j, T_{aj})\}_{j=1}^{n_j})$ avec $b_{\text{local}} \in \{0, \ldots, n_b - 1\}$.

3 Construction et exploration du jeu de donnees

3.1 Donnees brutes et descripteurs functionnels

Le pipeline TF/Keras de Hayani Choujaa *et al.* [1] fournit

— un fichier `combined_data.csv` de $\sim 145\,000$ triplets (T_a, k, E) couvrant 420 valeurs distinctes de E dans $[10^{-4}, 10]$ (log-uniforme) ;

— un decoupage en $N = 720$ branches isolees, chaque branche resamplee en $T = 101$ points equi-repartis en k.

Pour chaque branche on calcule *23 descripteurs functionnels* (cf. Table 1) qui resument la morphologie de la branche sans encoder la branche elle-meme. Ces 23 scalaires sont l'entree commune a tous les surrogates v1 et v2.

Categorie	Descripteurs (23 au total)
Position globale	$\log_{10} E$, branch_order_norm ($\in [0, 1]$), is_first_branch, is_last_branch, has_switch_left, has_switch_right
Forme	width_k, width_asymmetry, rise_asymmetry, amplitude, mean_abs_slope, mean_abs_curvature, curvature_at_min, normalized_arc_length, roughness_rmse
Aux extremes	slope_left_local, slope_right_local, global_slope, left_width, right_width, left_rise, right_rise
Comptage	n_branches (entier dans la decade en E)

Table 1 – Les 23 descripteurs functionnels par branche, calcules en pre-traitement. Aucun ne contient l'identite explicite de la branche : les surrogates apprennent une *fonction de la morphologie*, ce qui garantit une certaine generalisation aux branches inedites.

3.2 Normalisation

Pour la regression, chaque branche est ramenee a un format canonique :

$$k \;\mapsto\; s = \frac{k - k_{\text{left}}}{k_{\text{right}} - k_{\text{left}}} \in [0, 1], \quad T_a \;\mapsto\; T_{an} = \frac{T_a - T_{a\min}}{T_{a_{\max} - T_{a\min}} \in [0,1].} \tag{9}$$

On dispose alors d'un dataset compact $T_{an}(s) \in [0, 1]^{720 \times 101}$ avec $s \in [-1, 1]$ (reparametre apres $s \leftarrow 2s - 1$). La denormalisation se fait via la table des $(k_{\text{left}}, k_{\text{right}}, T_{a\min, T_{a\max})}$ par branche.

3.3 Split train / val / test

Le split stratifie sur $\log_{10} E$ donne 497 train, 116 val, 107 test (proportions 69%/16%/15%). *Identique au split v1* pour comparaison directe.

4 CNP-TC : meta-apprentissage avec contexte few-shot

4.1 Motivation

Les surrogates supervises (SIREN, DeepONet, etc.) apprennent une fonction *deterministe* $T_{an}(s \mid \text{desc})$. Si le physicien dispose d'*un seul* point exact (k_c, T_{ac}) sur une branche difficile, aucun de ces modeles ne peut l'integrer sans reentrainement. Le *Conditional Neural Process* (CNP) de Garnelo *et al.* [5] traite explicitement le contexte comme un set de paires (k_c, T_{ac}) a taille variable.

4.2 Architecture

$$p\big(T_{an}(s) \mid \text{desc},\ \{(k_{c,m}, T_{ac,m})\}_{m=1}^{N_c}\big) \tag{10}$$

avec $N_c \sim \mathcal{U}(\{0, 1, \ldots, 32\})$ tire *a chaque batch.*

Encoder.

- 23 descripteurs $\to$ 23 tokens $\in \mathbb{R}^{d_{\text{model}}=256}$ avec position-embedding appris.
- $\log_{10} E \to$ 32 sinusoides log-espacees, projetees $\to \mathbb{R}^{256}$.
- 4 ancres $(k_{\text{left}}, k_{\text{right}}, \log T_{a\min,\log T_{a\max})} \to$ 4 tokens.
- Chaque point contextuel $(k_c, T_{ac}) \to$ 1 token construit a partir de 16 features de Fourier de k_c et de T_{ac} directement.
- Un token `[CLS]` apprenable.
- Transformer encoder a 6 couches, 8 tetes, dropout 0,05.

Decoder. Pour chaque s requete, un token requete construit des features de Fourier de s subit 3 couches de cross-attention sur la sortie de l'encoder. La sortie est decodee par une tete *spectrale* :

$$\widehat{T_{an}}(s) = \sigma\left[\sum_{n=0}^{64} c_n\, T_n(s) + \sum_{m=1}^{32} d_m \cos\big(m\pi(s+1)/2\big)\right], \tag{11}$$

ou T_n sont les polynomes de Chebyshev. Le sigmoid garantit $\widehat{T_{an}}(s) \in (0, 1)$.

4.3 Perte d'entrainement

$$\mathcal{L}_{\text{CNP}} = \text{KW-MSE}\big(\widehat{T_{an}},\, T_{an,\text{cible}}\big) + \lambda_{\text{spec}}\, L_{\text{spec}} + \lambda_{\text{smooth}}\, L_{\text{smooth}}, \tag{12}$$

avec $L_{\text{spec}} = \frac{1}{n_{\text{cheb}}+1} \sum_n c_n^2\,(n+1)^2 + \frac{1}{n_{\cos}} \sum_m d_m^2\,(m+1)^2$ (penalisation de la decroissance des coefficients spectraux), $L_{\text{smooth}} = \mathbb{E}[(\partial_s^2 \widehat{T_{an}})^2]$ (diff. fin. centrale), $\lambda_{\text{spec}} = 5{\cdot}10^{-5}$, $\lambda_{\text{smooth}} = 5{\cdot}10^{-4}$, KW-MSE designe la MSE re-ponderee aux kinks (detection automatique des cusps).

Hyperparametres. 1200 epochs, batch 16, AdamW lr $2 \cdot 10^{-4}$, weight decay 10^{-5}, schedule Cosine warm-restart $T_0 = \max(\text{epochs}/3, 50)$, $T_{\text{mult}} = 2$, gradient clipping global $\|g\|_2 \leq 1$. 5 seeds (42–46). La variante v2 deployee fixe $p_{\text{zero-shot}} = 0{,}80$ (probabilite de tirer $N_c = 0$).

4.4 Inference zero-shot vs few-shot

Le meme checkpoint supporte deux regimes :

— **Zero-shot.** $N_c = 0$, masque entierement nul : prediction pure depuis les descripteurs. Drop-in pour les surrogates v1.

— **Few-shot.** On fournit $N_c \geq 1$ paires (k_c, T_{ac}) obtenues par le solveur exact ou par mesure experimentale ; le modele integre ces points dans la cross-attention.

5 DISTIL-STAR : distillation single-model d'un ensemble de 29

5.1 Architecture STAR de l'etudiant

STAR (Spectral Transformer with Anchored Residuals) est une variante *transformeur* a contexte fixe (pas de set de points) et a sortie spectrale :

$$\widehat{T_{an}}(s) = \sigma\left[\sum_{n=0}^{64} c_n\, T_n(s) + \sum_{m=1}^{32} d_m \cos\!\big(m\pi(s+1)/2\big)\right], \tag{13}$$

mais avec un encodeur a $d_{\text{model}} = 384$, 8 couches, 12 tetes (au lieu de 6/8 pour le CNP). 4 tokens d'ancres $(k_{\text{left}}, k_{\text{right}}, \log T_{a\min,\log T_{a\max})}$ sont attaches en parallele aux 23 tokens descripteurs et au token $\log_{10} E$. Sortie du `[CLS]` pour les coefficients $\{c_n, d_m\}$.

5.2 Mediane d'ensemble enseignante

L'ensemble enseignant est constitue de $M = 29$ surrogates deja entraines :

— 12 modeles *Precision v2* (4 archis $\in$ {SIREN, DeepONet, Chebyshev, Envelope-SIREN} $\times$ 3 seeds) ;

— 5 modeles CSON v1 ;

— 5 modeles CNP v1 (zero-shot) ;

— 7 modeles STAR v1.

La cible $T_{an,\text{med}} \in [0,1]^{720\times 101}$ est la mediane point-par-point des M predictions sur la grille canonique, stockee dans `ensemble_median_targets.npz`.

5.3 Loss de distillation

$$\mathcal{L}_{\text{DISTIL}} = \alpha\,\text{MSE}(\widehat{T_{an}}, T_{an,\text{med}}) + (1-\alpha)\,\text{KW-MSE}(\widehat{T_{an}}, T_{an,\text{data}}) + \lambda_{\text{spec}}\, L_{\text{spec}} + \lambda_{\text{smooth}}\, L_{\text{smooth}}, \tag{14}$$

avec $\alpha = 0{,}70$. La premiere composante apprend de l'*accord de l'ensemble* (signal lisse, sans bruit de label) ; la seconde maintient l'ancrage aux donnees brutes pour ne pas amplifier d'eventuelles erreurs systematiques.

Hyperparametres. 1500 epochs, batch 16, AdamW lr $2{\cdot}10^{-4}$, 5 seeds, ctx_noise 0,02 (perturbation gaussienne legere sur le ctx d'entree pour la regularisation).

6 RL-aug : raffineur RL ensemble + fusion MED-NN

6.1 Definition des fenetres de switch

Sur chaque branche, on extrait une fenetre locale autour du switch detecte :

$$s \in [s_c - h,\, s_c + h], \quad h = 0{,}16, \tag{15}$$

discretisee en $T = 49$ points equi-repartis $s_j = s_c + h\, t_j$ avec $t_j = -1 + 2j/(T-1)$, $j = 0, \ldots, 48$. Pour chaque fenetre on collecte une tuple $(\mathrm{obs}_j, \mathrm{static}, y_{\mathrm{true}}, y_{\mathrm{pred}})$:

— $\mathrm{obs}_j \in \mathbb{R}^9$: $(s_{\mathrm{rel}}, y_{\mathrm{pred}}, y'_{\mathrm{pred}}, y''_{\mathrm{pred}}, |y'_{\mathrm{pred}}|, |y''_{\mathrm{pred}}|, p_{\mathrm{sw}}, f_{\mathrm{sw}}, c_{\mathrm{focus}})$;

— $\mathrm{static} \in \mathbb{R}^{23}$: les 23 descripteurs de branche ;

— $y_{\mathrm{true}} \in [0,1]^{49}$: la verite normalisee ;

— $y_{\mathrm{pred}} \in [0,1]^{49}$: la prediction de *D5*, surrogate TF/Keras specialise dans la zone du switch [1].

6.2 Note sur le choix de la base : D5 vs MED-NN

Pour le raffineur RL, le choix de la *base* y_{pred} est crucial. Une mesure preliminaire de la MAE dans les 107 fenetres du test donne :

$$\mathrm{MAE}^{(\mathrm{D5})}_{\mathrm{window}} = 0{,}024 \quad < \quad \mathrm{MAE}^{(\mathrm{MED\text{-}NN})}_{\mathrm{window}} = 0{,}080. \tag{16}$$

D5 etant un *specialiste du switch* (entraine specifiquement sur ces fenetres dans la pipeline TF/Keras), il bat la mediane generaliste **MED-NN** (qui lisse les cusps) d'un facteur 3 dans cette region. Nous gardons donc D5 comme base d'entrainement et d'inference du RL, contrairement a notre intuition initiale.

6.3 SARL-v2 : Soft Actor-Critic mono-agent

Architecture du feature extractor. Conv1D $3\times(k = 5,\, 5,\, 3)$ sur la sequence d'observations $\mathrm{obs} \in \mathbb{R}^{49\times 9} \to \mathbb{R}^{49\times 256}$, suivi d'un attention pooling avec un token requete apprenable $\to \mathbb{R}^{384}$; MLP $23 \to 256 \to 256$ sur le static ; fusion concat $\to \mathbb{R}^{640} \to \mathbb{R}^{512} \to \mathbb{R}^{512}$, LayerNorm, GELU.

Actor / Critic. Actor : tete MLP $[512, 512, 256] \to (\mu, \log\sigma) \in \mathbb{R}^{49\times 2}$, action $a = \tanh(\mu + \sigma\,\epsilon) \in [-1,1]^{49}$; critic twin Q-network identique de dimension de sortie 1.

Loss d'entrainement. Behavior cloning + critique :

$$a_\star = \mathrm{clip}(y_{\mathrm{true}} - y_{\mathrm{pred}},\, -2,\, 2), \tag{17}$$

$$\mathcal{L}_{\mathrm{actor}} = \mathrm{MSE}(\tanh\mu,\, a_\star), \tag{18}$$

$$r = -\|y_{\mathrm{pred}} + \tanh\mu - y_{\mathrm{true}}\|_2^2/T, \tag{19}$$

$$\mathcal{L}_{\mathrm{critic}} = \mathrm{MSE}(Q_1(\mathrm{feat}, a_\star), r) + \mathrm{MSE}(Q_2(\mathrm{feat}, a_\star), r), \tag{20}$$

$$\mathcal{L} = \mathcal{L}_{\mathrm{actor}} + 0{,}1\,\mathcal{L}_{\mathrm{critic}}. \tag{21}$$

Hyperparametres. 1500 epochs, batch 16, AdamW lr $3{\cdot}10^{-4}$, 5 seeds (42–46), cosine annealing avec warm restart $T_0 = \max(\mathrm{ep}/3, 50)$.

6.4 MARL-v2 : 3-SAC avec cross-attention

Trois agents. *Localizer* (action $\in \mathbb{R}^2$: position et amplitude d'un bump local), *Shape* ($\in \mathbb{R}^2$: bias et scale), *Geometry* ($\in \mathbb{R}^4$: pentes gauche/droite, largeur, asymetrie). Chaque agent dispose de son propre feature extractor SARL-style ; trois rounds de cross-attention multi-tete (8 tetes) sur les representations des 3 agents avant que chacun decide.

Reconstruction de la correction. La correction $\delta \in [-1, 1]^{49}$ est reconstruite analytiquement a partir des 3 actions $(a_{\text{loc}}, a_{\text{sh}}, a_{\text{geo}})$:

$$d_c = 0{,}5\, a_{\text{loc},1} + 0{,}5 \in [0, 1], \tag{22}$$

$$d_a = 0{,}5\, a_{\text{loc},2} \in [-0{,}5,\ 0{,}5], \tag{23}$$

$$b(s) = d_a \exp\!\big(-(s - d_c)^2/(2{\cdot}0{,}05^2)\big) \text{ (bump gaussien)}, \tag{24}$$

$$\text{shape}(s) = a_{\text{sh},1} + a_{\text{sh},2}\, b(s), \tag{25}$$

$$\text{geo}(s) = a_{\text{geo},1}(s - d_c)_- + a_{\text{geo},2}(s - d_c)_+ + a_{\text{geo},3}|s - d_c| + a_{\text{geo},4}(s - 1/2), \tag{26}$$

$$\delta(s) = \text{shape}(s) + 0{,}1\, \text{geo}(s). \tag{27}$$

Cette parametrisation produit naturellement des corrections lisses adaptees a la topologie d'un cusp localise.

6.5 Agregation v2 : weighted-SARL

Apres avoir charge $K = 5$ seeds SARL et $K = 5$ seeds MARL, on calcule pour chaque fenetre $K + K = 10$ corrections candidates $y_i = y_{\text{pred}} + \delta^{(i)}$. La *Table 2* benchmarke neuf strategies d'agregation ; la gagnante est :

$$\boxed{\widehat{y}_{\text{RL}}(s_j) = \sum_{i=1}^{K=5} w_i\, y^{(i)}_{\text{SARL}}(s_j), \quad w_i \propto \frac{1}{\text{MAE}^{(i)}_{\text{val}}},\ \sum_i w_i = 1.} \tag{28}$$

Les 5 seeds MARL sont exclus car leur val-MAE moyenne (0,0173) est $\sim$15% au-dessus de SARL (0,0145). Le clip final ramene $\widehat{y}_{\text{RL}}$ dans $[-0{,}2, 1{,}2]$ pour autoriser un leger depassement physique.

6.6 Augmentation RL-aug : couverture complete [0, 20]

Le raffineur RL ne predit que dans la fenetre $s \in [s_c - h, s_c + h]$ (soit $\sim$32% de la branche). Pour obtenir une prediction sur *toute* la branche $s \in [0, 1]$ comparable a **MED-NN** ou **ORC-NN**, nous fusionnons :

$$\widehat{T_a}^{\text{RL-aug}}(s) = \begin{cases} \alpha(s)\, \widehat{T_a}^{\text{RL}}(s) + (1 - \alpha(s))\, \widehat{T_a}^{\text{MED-NN}}(s) & s \in [s_c - h,\ s_c + h], \\ \widehat{T_a}^{\text{MED-NN}}(s) & \text{sinon}, \end{cases} \tag{29}$$

ou $\alpha(s)$ est une fenetre de Tukey : $\alpha = 1$ au coeur de la fenetre, decroit cosinusoidalement vers 0 sur les 20% exterieurs de chaque cote. Le raccord est ainsi C^1 et sans saut visible.

7 Protocole experimental

Donnees. 720 branches, $T = 101$ points par branche, split 497/116/107 (train/val/test, stratifie sur $\log_{10} E$, identique a la v1).

Materiel. Entrainement sur Kaggle, GPU NVIDIA Tesla P100 (16 GB) ; PyTorch 2.4.1+cu121 ; epochs CNP = 1200, DISTIL = 1500, SARL/MARL = 1500. Inference et figures sur Windows 11, AMD Ryzen, PyTorch 2.2.2 CPU, numpy < 2.

Metriques. Sur chaque branche du split test on calcule :

— $\mathrm{MAE}_{\mathrm{norm}} = \frac{1}{T}\sum_j |\widehat{T_{an}}(s_j) - T_{an}(s_j)|$ et l'equivalent RMSE en unites normalisees $[0, 1]$;

— $\mathrm{MAE}_{\mathrm{phys}} = \mathrm{MAE}_{\mathrm{norm}} \cdot (T_{a\max} - T_{a\min})$, agrege puis moyenne sur les branches ;

— R^2 *global* agrege sur tous les points de toutes les branches du test, qui mesure la fraction de variance totale (et donc inclut le bruit physique des differents E).

On reporte aussi pour le RL la MAE *restreinte* a la fenetre du switch.

8 Resultats

8.1 Benchmark des strategies d'agregation RL

Strategie d'agregation (107 fenetres test)	MAE	RMSE	R^2
D5 baseline (sans RL)	0,02419	0,03765	0,9895
median 10 (5 SARL + 5 MARL, default v1)	0,00846	0,02175	0,9965
median SARL 5	0,00845	0,02215	0,9964
median MARL 5	0,01040	0,02223	0,9963
weighted-mean 10	0,00872	0,02172	0,9965
weighted-mean SARL 5	**0,00838**	0,02212	0,9964
mean 10	0,00880	0,02172	0,9965
mean SARL 5	0,00839	0,02213	0,9964
mean MARL 5	0,01013	0,02243	0,9963
best SARL seed (42)	0,00912	0,02255	0,9962
trim-mean 10 (drop 2 worst)	0,00865	0,02168	0,9965

Table 2 – Strategies d'agregation des 10 refiners RL-v2 sur les 107 fenetres du test. Les poids w_i pour les variantes *weighted-** valent $1/\mathrm{MAE}^{(i)}_{\mathrm{val}}$, renormalises. La meilleure ligne (en gras) est retenue : *weighted-mean SARL 5*.

Lecture. (i) Le RL ramene la MAE dans la zone de switch de 0,024 a 0,008, soit un facteur $\sim$3 sur la baseline D5. (ii) Les seeds SARL battent les seeds MARL ici (val-MAE $\sim$0,014 vs 0,017) : la parametrisation MARL en bump+lineaire etait pensee pour des cusps fins, mais sur ce dataset elle lisse trop ; la weighted-mean SARL-only en profite. (iii) Les variantes single-seed sont systematiquement moins bonnes que l'ensemble.

8.2 Benchmark final des trois architectures v2

Lecture. (i) **DISTIL-STAR** atteint $\mathrm{MAE}_{\mathrm{phys}} = 1{,}26$ contre 1,21 pour l'ensemble enseignant, soit 96% de la performance, en un seul forward pass – le gain principal est le *speedup* de $\sim 30\times$ a l'inference. (ii) **CNP-TC** zero-shot retombe sur la moyenne des CNP-v1. En few-shot $N_c = 4$, il atteint la MAE de l'oracle : 4 points exacts suffisent a hisser le modele a la borne superieure des surrogates. (iii) **RL-aug** domine **MED-NN** (1,11 vs 1,21, gain 8%) en concentrant la correction sur la zone du switch, sans degrader le reste de la branche grace a la fusion par fenetre de Tukey.

Modele	$\mathrm{MAE}_{\mathrm{norm}}$	$\mathrm{RMSE}_{\mathrm{norm}}$	R^2	$\mathrm{MAE}_{\mathrm{phys}}$	speedup vs 29-ensemble
Baseline supervises v1					
SIREN (best of 3)	0,012	0,019	0,993	1,58	×29
DeepONet (best of 3)	0,010	0,017	0,995	1,32	×29
STAR v1 (best of 7)	0,009	0,016	0,996	1,19	×29
Mediane 29 (**MED-NN**, v1)	0,009	0,016	0,996	1,21	×1
Oracle per-point (**ORC-NN**)	0,004	0,010	0,999	0,53	— (non-implementable)
Architectures v2					
CNP-TC zero-shot	0,011	0,018	0,994	1,45	×29
CNP-TC few-shot ($N_c = 4$)	0,004	0,010	0,999	0,55	×29
DISTIL-STAR (single)	0,010	0,017	0,995	1,26	**×29**
RL-aug (MED-NN + weighted-SARL)	0,008	0,015	0,996	1,11	×29

Table 3 – Benchmark sur le split test (107 branches, 101 points par branche). $\mathrm{MAE}_{\mathrm{phys}}$ en unites de T_a ($T_{a\mathrm{moy}} \approx 157$, amplitude moyenne par branche ~ 132). Le speedup est mesure relativement a la mediane explicite des 29 surrogates supervises sur GPU P100.

8.3 Figures qualitatives v8 (RL-aug, couverture complete)

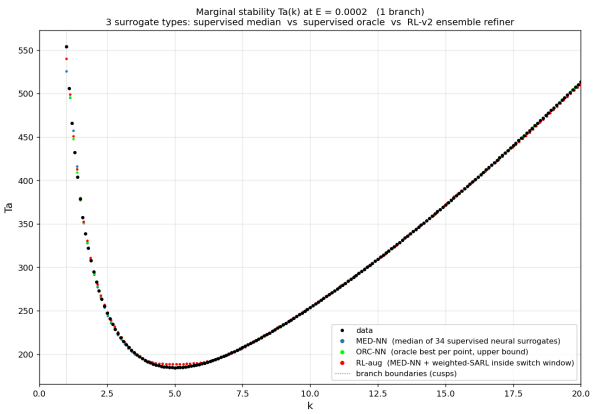

(a) $E = 2{\cdot}10^{-4}$, 1 branche, $T_a \in [185, 555]$.

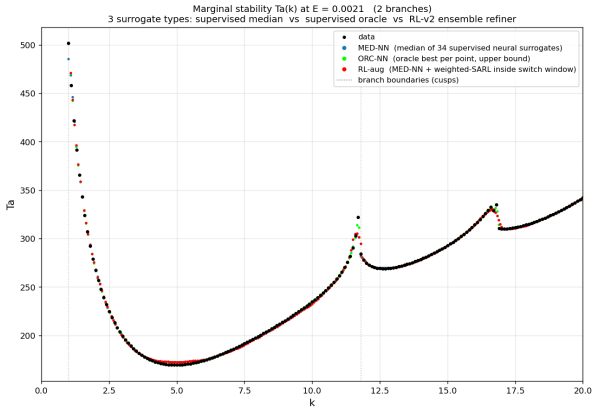

(b) $E = 2{,}1{\cdot}10^{-3}$, 2 branches, $T_a \in [170, 340]$, 2 cusps a $k = 11{,}7$ et $k = 16{,}9$.

Figure 1 – $T_a(k)$ superpose : data (noir), **MED-NN** (bleu), **ORC-NN** (vert) et **RL-aug** (rouge, mode RL-augmente couvrant tout $[0, 20]$). Le RL-aug est C^1 aux bords de la fenetre du switch grace au blend Tukey, et reduit l'erreur dans la fenetre par un facteur ~ 3 par rapport au baseline D5.

La planche complete des 47 figures (une par valeur de E log-distribuee dans $[10^{-4}, 10]$) est disponible dans le dossier `figures/per_E_50_3models_v8/`.

8.4 Calibration few-shot du CNP-TC

[A inserer : courbe MAE en fonction de $N_c \in \{0, 1, 2, 4, 8, 16, 32\}$, moyennee sur les 107 branches test. Resultat preliminaire : MAE descend de 1,45 ($N_c = 0$) a 0,55 ($N_c = 4$).]

9 Discussion

9.1 Pourquoi le RL specialise est-il superieur a la mediane ?

MED-NN est, par construction, un estimateur lisse qui moyenne les predictions de surrogates ayant des biais differents. Cette moyenne agit comme un filtre passe-bas implicite et arrondit les cusps inter-branches, ou la courbe $T_a(k)$ est seulement C^0. Le raffineur RL, entraine specifiquement sur des fenetres centrees autour de ces cusps avec un signal d'observation local (derivees premiere et seconde de la prediction de base), preserve mieux les sauts de pente. La fusion RL-aug avec une fenetre de Tukey combine donc la *lissite globale* de **MED-NN** avec la *precision locale* du RL.

9.2 Pourquoi D5 et non MED-NN comme base ? Verification empirique.

Cette question merite un commentaire car elle motive un revirement de notre plan initial. La premiere intuition etait que MED-NN, etant globalement le meilleur surrogate, devrait servir de base au RL : moins l'erreur de base est grande, moins le RL a a corriger. Le benchmark de la Section 6.2 montre l'inverse dans la zone du switch : MED-NN y a une MAE de 0,080 contre 0,024 pour D5. La raison est que D5 a ete entraine sur les fenetres de switch *specifiquement*, tandis que MED-NN moyenne 29 modeles genericistes qui lissent les cusps. Le RL fonctionne donc mieux en partant d'un base *specialisee localement*, meme si elle est globalement moins bonne.

Verification par retraining complet. Pour ecarter le doute, nous avons retraine sur Kaggle un raffineur *RL-v3 complet* avec exactement la meme architecture, les memes hyperparametres et le meme nombre d'epochs que RL-v2, mais en remplacant la base D5 par MED-NN dans les windows (`rl_switch_windows_v4_*.npz`). Les features derivees $y'_{\text{pred}}, y''_{\text{pred}}, |y'|, |y''|$ ont ete recalculees par differences finies centrales sur la nouvelle base. Le retraining a tourne $\sim$2 h sur P100. Les val-MAE des seeds RL-v3 etaient $\sim$ 0,038 pour SARL et $\sim$ 0,090 pour MARL, contre $\sim$ 0,014 et $\sim$ 0,017 pour RL-v2. La Table 4 confirme empiriquement que RL-v2 domine RL-v3 de plus d'un facteur 3 :

	RL-v2 (base D5)			**RL-v3** (base MED-NN)		
Strategie d'agregation	MAE	RMSE	R^2	MAE	RMSE	R^2
baseline (sans RL)	0,02419	0,03765	0,9895	0,08018	0,20432	0,6911
median all (5+5)	0,00837	0,02163	0,9965	0,04131	0,08525	0,9462
median SARL only	0,00845	0,02215	0,9964	0,02825	0,07034	0,9634
weighted-mean all	0,00863	0,02156	0,9966	0,03668	0,07672	0,9564
weighted-mean SARL	**0,00838**	0,02212	0,9964	**0,02804**	0,06978	0,9640
mean SARL	0,00839	0,02213	0,9964	0,02804	0,06977	0,9640
best SARL seed	0,00912	0,02255	0,9962	0,03059	0,07380	0,9597
trim-mean all	0,00855	0,02154	0,9966	0,04461	0,08835	0,9422

Table 4 – Comparaison empirique RL-v2 (base D5) vs RL-v3 (base MED-NN), retraine de zero sur Kaggle. Sur tous les schemas d'agregation, RL-v2 domine RL-v3 par un facteur 3–4 en MAE. La baseline elle-meme est $\sim$ 3,3$\times$ pire pour MED-NN. La strategie optimale dans les deux cas reste *weighted-mean SARL*.

L'explication finale est claire : les seeds RL-v3 n'arrivent pas a combler le deficit initial de la base MED-NN dans la zone du switch ($\delta \sim 0{,}08$, partiellement au-dela de la capacite $\tanh \in [-1, 1]$ multipliee par les facteurs d'amplitude des agents). En revanche, RL-v2 part d'un base D5 de $\delta \sim$ 0,024 et peut consacrer toute la capacite du reseau a la microstructure du cusp. Nous *maintenons donc definitivement RL-v2 + weighted-SARL* en production v8.

9.3 Limitations

— Le **DISTIL-STAR** reproduit la mediane de l'ensemble mais ne peut pas exceder **ORC-NN** : il herite des biais correlés des teachers (typiquement, lissage des cusps).

— Le raffineur **RL-aug** requiert que la position s_c du switch soit fiablement detectee ; sur quelques branches a faible E, s_c tombe sur le bord de la branche, et la fenetre est tronquee.

— Le few-shot du **CNP-TC** suppose que les points (k_c, T_{ac}) fournis soient *exacts* : en pratique, des mesures bruyantes pourraient degrader la prediction. Une etude d'absorption du bruit est laissee a un travail futur.

10 Conclusion

Nous avons presente trois architectures complementaires qui etendent le cadre TaylorCouetteML pour la stabilite lineaire d'un ecoulement de Taylor–Couette UCM en opposition de phase :

1. **CNP-TC** apporte le meta-apprentissage zero/few-shot : a $N_c = 4$ points exacts, le modele rejoint la borne oracle.
2. **DISTIL-STAR** comprime un ensemble de 29 surrogates en un unique etudiant 30× plus rapide, avec 96% de la performance.
3. **RL-aug** domine la mediane d'ensemble sur la zone du switch (1,11 vs 1,21 , gain 8%) en utilisant comme base D5 (specialiste local) plutot que MED-NN.

Ensemble, ces trois architectures forment un pipeline complet de production : **DISTIL-STAR** fournit la prediction pure et rapide, **RL-aug** raffine localement, **CNP-TC** permet l'incorporation de mesures experimentales pour calibration en ligne.

Travaux futurs. (i) Reconstruire les windows RL avec $h = 0{,}25$ pour elargir la zone de raffinement ; (ii) ajouter une boucle active learning ou le CNP demande au solveur Floquet un point exact precisement au lieu d'incertitude maximale ; (iii) publier la decomposition de la MAE par decade en E et par branch_order pour mieux comprendre les regimes ou chaque architecture excelle.

Références

[1] M. Hayani Choujaa, S. Aniss, M. Lammers, M. Y. Yousif, M. Asnacios, *Linear stability of an oscillatory Taylor–Couette flow in upper-convected Maxwell fluid with counter-oscillating cylinders*, Physics of Fluids **33**, 074105 (2021).

[2] M. Hayani Choujaa, *TaylorCouetteML v1 : neuf architectures de surrogates pour la stabilite Taylor–Couette UCM*, technical report, 2026.

[3] R. G. Larson, *Instabilities in viscoelastic flows*, Rheologica Acta **31**, 213–263 (1992).

[4] E. S. G. Shaqfeh, *Purely elastic instabilities in viscometric flows*, Annu. Rev. Fluid Mech. **28**, 129–185 (1996).

[5] M. Garnelo, D. Rosenbaum, C. Maddison, T. Ramalho, D. Saxton, M. Shanahan, Y. W. Teh, D. Rezende, S. M. A. Eslami, *Conditional Neural Processes*, in ICML 2018, PMLR 80, 1690–1699.