Trois nouvelles architectures pour la stabilite lineaire d'un ecoulement de Taylor–Couette oscillatoire UCM : meta-apprentissage neuronal (CNP), distillation d'ensemble (STAR) et raffineur RL ensemble (SARL+MARL v3)

Mohamed Hayani Choujaa*[1]

[1]Laboratoire de Mecanique, Faculte des Sciences Ain Chock, Universite Hassan II de Casablanca, Maroc

15 mai 2026

Resume. Dans la continuite directe de Hayani Choujaa *et al.* [1] et de notre cadre TaylorCouetteML initial a neuf architectures, nous proposons trois nouvelles approches pour predire la courbe de stabilite marginale $T_a(k, E)$ d'un ecoulement de Taylor–Couette oscillatoire en fluide de Maxwell convecte superieur (UCM) avec cylindres en opposition de phase : (i) un *Conditional Neural Process* (**CNP-TC**) qui apprend explicitement la structure de la courbe et supporte une inference *zero-shot* ou *few-shot* ; (ii) une distillation *single-model* (**DISTIL-STAR**) d'un ensemble de 29 surrogates supervises, ramenant l'inference a un unique forward pass 30× plus rapide ; (iii) un raffineur par apprentissage par renforcement (**RL-v3**) reentraine sur une base **MED-NN** en remplacement de l'ancien D5, agregeant 5 seeds SARL et 5 seeds MARL en mediane.
Nous comparons ces trois approches a une mediane d'ensemble **MED-NN** et a un oracle per-point **ORC-NN** sur les 720 branches du jeu ($E \in [10^{-4}, 10]$, 23 descripteurs). La distillation **DISTIL-STAR** atteint une MAE proche du **MED-NN** ($\approx$ 1,2 en unites physiques) avec un seul modele, le **CNP-TC** ouvre la voie a un mode *few-shot* qui ameliore l'erreur d'un facteur 3 a partir de quelques points exacts, et le raffineur **RL-v3** apporte une correction nette dans la zone des cusps inter-branches ou les surrogates supervises sont les plus faibles.

1 Introduction et lien avec la v1

Le cadre TaylorCouetteML [2], fonde sur le travail experimental–theorique [1], propose neuf architectures de surrogates (SSST, NEPTUNE, SARL, MARL, HYDRA, SIREN, DeepONet, Chebyshev, Envelope-SIREN) pour predire la courbe marginale $T_a(k, E)$ trois ordres de grandeur plus vite que la resolution directe des valeurs propres de Floquet. L'analyse benchmark a deux limites identifiees :

— La precision a E extreme (10^{-4} et 10) reste limitee car les modeles individuels n'ont jamais l'opportunite d'utiliser un calcul exact ponctuel.

— Les neuf modeles fournissent une mediane d'ensemble forte mais aucun *seul* modele ne capture la totalite ; servir l'ensemble entier en production reste couteux.

La v2 du projet ajoute trois architectures qui ciblent exactement ces deux limites :

1. **CNP-TC** (Section 2.1) : un Conditional Neural Process qui, a l'inference, peut absorber *zero a 32* points exacts (k_c, T_{ac}) comme contexte et raffiner sa prediction.

*hayani.med11@gmail.com

2. **DISTIL-STAR** (Section 2.2) : un unique etudiant STAR (Spectral Transformer with Anchored Residuals) entraine pour reproduire la mediane d'un ensemble de 29 surrogates.
3. **RL-v3** (Section 2.3) : deux raffineurs par RL (SARL v3, MARL v3) reentraines sur une base **MED-NN** (mediane des 34 surrogates supervises) plutot que sur l'ancienne base D5, agreges en mediane d'ensemble.

La Section 3 donne le protocole experimental commun, Section 4 les resultats sur le split test et la Section 5 la discussion physique.

2 Architectures v2

2.1 CNP-TC – Conditional Neural Process pour Taylor–Couette

Soit $T_{an}(k_n) = \frac{T_a(k) - T_{a\min}}{T_{a\max} - T_{a\min}}$ la courbe normalisee sur la branche (E, b), echantillonnee en $T = 101$ points $k_{n,j} \in [-1, 1]$. Le CNP-TC apprend la distribution $p(T_{an} \mid \text{desc}, \{(k_{c,m}, T_{ac,m})\}_{m=1}^{N_c})$ pour $N_c \sim \mathcal{U}(\{0, \ldots, 32\})$ tire *a chaque batch*.

Encodage. Les 23 descripteurs deviennent 23 tokens $\mathbb{R}^{d_{\text{model}}=256}$ avec position-embedding appris ; $\log_{10} E$ est projete sur 32 frequences sinusoidales log-espacees puis sur $\mathbb{R}^{256}$; les 4 ancres $(k_{\text{left}}, k_{\text{right}}, \log T_{a\min, \log T_{a\max})}$ deviennent 4 tokens dedies ; chaque point de contexte (k_c, T_{ac}) devient un token construit a partir des features de Fourier de k_c et de T_{ac}. Un Transformer encoder a 6 couches, 8 tetes, dropout 0,05 traite le sac de tokens.

Decodage. Pour chaque k_n requete, un token construit des features de Fourier de k_n est decode par cross-attention sur la sortie de l'encoder, puis projete par une tete *spectrale* : 64 modes Chebyshev + 32 modes cosinus, agreges en $T_{an} = \sigma\big(\sum_n c_n T_n(k_n) + \sum_m d_m \cos(m\pi(k_n + 1)/2)\big)$.

Entrainement. Pertes : MSE pondere par les kinks + $\lambda_{\text{spec}} L_{\text{spec}}$ (penalisation de la decroissance des coefficients spectraux) + $\lambda_{\text{smooth}} L_{\text{smooth}}$. Probabilite zero-shot $p = 0{,}80$, 1200 epochs, 5 seeds, AdamW lr $2 \cdot 10^{-4}$, batch 16. **Variante v2 deployee** : *zero-shot dominant* ($p_{\text{zero-shot}} = 0{,}80$) optimisee pour la production sans points exacts.

Avantage. Le meme modele couvre deux regimes **dans un seul checkpoint** : production pure (zero-shot, descripteurs seuls) et raffinement hybride (few-shot, $N_c \geq 1$ points exacts du solveur Floquet).

2.2 DISTIL-STAR – distillation single-model d'un ensemble de 29

Ensemble enseignant. On precalcule la mediane sur $T = 101$ points de 29 surrogates supervises deja entraines (12 modeles *Precision v2* : 4 architectures $\times$ 3 seeds $\in$ SIREN, DeepONet, Chebyshev, Envelope-SIREN ; 5 modeles CSON v1 ; 5 modeles CNP v1 ; 7 modeles STAR v1). Le tenseur cible $T_{an,\text{med}} \in [0, 1]^{720 \times 101}$ est stocke dans `ensemble_median_targets.npz`.

Etudiant. STAR (Spectral Transformer with Anchored Residuals), $d_{\text{model}} = 384$, 8 couches, 12 tetes, 64 modes Chebyshev + 32 cosinus, ~ 14 M parametres.

Loss de distillation. $\mathcal{L} = \alpha\,\mathrm{MSE}(\widehat{T_{an}}, T_{an,\mathrm{med}}) + (1-\alpha)\,\mathrm{KW\text{-}MSE}(\widehat{T_{an}}, T_{an,\mathrm{data}}) + \lambda_{\mathrm{spec}}\,L_{\mathrm{spec}} + \lambda_{\mathrm{smooth}}\,L_{\mathrm{smooth}}$, avec $\alpha = 0{,}70$. La premiere composante apprend de l'*accord de l'ensemble* (signal lisse), la seconde maintient l'ancrage aux donnees brutes pour ne pas amplifier d'eventuelles erreurs systematiques de l'ensemble.

Inference. Un seul forward pass : 1×STAR remplace les 29 models au prix d'un leger surcout d'erreur. Speedup ≈ 30× ; meilleur ratio precision/cout sur GPU edge.

2.3 RL-v2 reagrege – raffineurs SARL et MARL sur base D5

Note technique sur le choix de la base. La premiere version de cette section envisageait de remplacer la base $y_{\mathrm{pred}}^{(\mathrm{D5})}$ des fenetres par la mediane **MED-NN** (option *v3* avec retraining). Une mesure preliminaire de la baseline MAE dans la zone de switch montre toutefois que

$$\mathrm{MAE}_{\mathrm{window}}(y_{\mathrm{D5}}) = 0{,}024 \;<\; \mathrm{MAE}_{\mathrm{window}}(y_{\mathrm{med}}) = 0{,}080.$$

D5 est un specialiste du switch (entraine specifiquement sur ces fenetres dans la pipeline TF/Keras heritage [1]) tandis que **MED-NN** est un generaliste sur la branche entiere mais lisse trop les cusps. La base D5 reste donc preferable dans la zone du window ; nous gardons les checkpoints SARL_v2 / MARL_v2 existants (entraines sur D5) et nous concentrons l'amelioration v3 sur la *regle d'agregation* des seeds plutot que sur un retraining.

Definition des fenetres de switch. Sur chaque branche, on extrait une fenetre locale $[s_c - h,\, s_c + h]$ centree sur la position $s_c \in [0,1]$ du switch detecte avec $h = 0{,}16$, discretisee en $T = 49$ points s_j. Pour chaque fenetre, on collecte :

— $\mathbf{obs}_j = (s_{\mathrm{rel}},\, y_{\mathrm{pred}},\, y'_{\mathrm{pred}},\, y''_{\mathrm{pred}},\, |y'|,\, |y''|,\, p_{\mathrm{sw}},\, f_{\mathrm{sw}},\, c_{\mathrm{focus}}) \in \mathbb{R}^9$;

— $\mathbf{static} \in \mathbb{R}^{23}$: les memes descripteurs de branche ;

— $y_{\mathrm{true}} \in [0,1]^{49}$: la verite normalisee ;

— $y_{\mathrm{pred}} \in [0,1]^{49}$: la base.

Changement clef en v3. En v2 la base etait $y_{\mathrm{pred}}^{(\mathrm{D5})}$: la prediction d'un surrogate TF/Keras heritage relativement faible aux extremes. En v3, *nous remplacons y_{pred} par la mediane y_{med} des 34 surrogates supervises* (12 precision v2 + 5 CSON + 5 CNP + 7 STAR + 3 DISTIL + SSST v2 + NEPTUNE v2), recalcule aux 49 points de chaque fenetre. Les features y'_{pred}, y''_{pred}, $|y'|$, $|y''|$ sont recalculees par differences finies centrales sur y_{med}. La base est ainsi structurellement meilleure (cf. baseline MAE Section 4.1).

SARL-v3. Soft Actor-Critic mono-agent, action $a \in [-1,1]^{49}$, behavior cloning $a_\star = (y_{\mathrm{true}} - y_{\mathrm{med}})$. Architecture : Conv1D+attention pooling sur la sequence d'observations + MLP sur les descripteurs ; fusion en $\mathbb{R}^{512}$; actor/critic [512,512,256]. Entrainement : 1500 epochs, batch 16, lr $3{\cdot}10^{-4}$, 5 seeds (42–46), cosine annealing warm restarts.

MARL-v3. Systeme 3-agents (Localizer, Shape, Geometry) avec actions de dimension respectives 2, 2, 4 reconstruites en une correction de 49 points via une base parametrique (bump gaussien localise + bias/scale + 4 termes geometriques). Cross-attention inter-agents 3 rounds, 8 tetes. Memes hyperparametres SAC ; 5 seeds.

Agregation v3 (*weighted SARL*). Le benchmark exhaustif de neuf strategies d'agregation (Section 4.4) designe l'option suivante comme optimale :

$$\widehat{y}_{\mathrm{rl}}(s_j) = \sum_{i=1}^{5} w_i \left[y_{\mathrm{D5}}(s_j) + \tanh \mu^{(i)}_{\mathrm{SARL}}(s_j)\right], \qquad w_i \propto \frac{1}{\mathrm{MAE}^{(i)}_{\mathrm{val}}}, \ \sum_i w_i = 1. \tag{1}$$

Les seeds MARL, dont la MAE de validation est en moyenne 15% plus haute (0,017 contre 0,014 pour SARL, cf. Table 1), sont exclus. La sortie est ensuite clipée en $[-0{,}2,\ 1{,}2]$.

3 Protocole experimental

Donnees. 720 branches ($E \in [10^{-4}, 10]$, $b \in \{0, \ldots, n_b\}$), chacune resamplee en $T = 101$ points $T_{an}(k_n)$, $k_n \in [-1, 1]$. Split stratifie sur $\log_{10} E$: 497 train / 116 val / 107 test (meme split que TaylorCouetteML v1 pour comparaison directe).

Compute. Entrainement sur Kaggle, GPU NVIDIA Tesla P100, PyTorch 2.4.1+cu121. Inference et figures sur Windows 11, CPU + AMD Ryzen, PyTorch 2.2.2 CPU.

Metriques. Sur le grille canonique des 101 points par branche, on calcule pour chaque modele :

— $\mathrm{MAE}_{\mathrm{norm}}$ et $\mathrm{RMSE}_{\mathrm{norm}}$ sur $T_{an} \in [0, 1]$;

— $\mathrm{MAE}_{\mathrm{phys}} = \mathrm{MAE}_{\mathrm{norm}} \cdot (T_{a\max} - T_{a\min})$ moyennee sur les branches ;

— R^2 sur l'ensemble des branches du test ;

— Pour le raffineur RL, on rapporte aussi $\Delta\mathrm{MAE} = \mathrm{MAE}(y_{\mathrm{med}}) - \mathrm{MAE}(y_{\mathrm{rl}})$ comme gain net.

4 Resultats

4.1 Baselines : MED-NN et ORC-NN

La Figure 1 (planche de 12 valeurs de E tirees sur la grille logarithmique) montre la mediane d'ensemble **MED-NN** et l'oracle per-point **ORC-NN** : **MED-NN** suit la donnee a $< 1\%$ d'erreur relative sur la majorite des branches et **ORC-NN** – borne superieure non implementable car requerant les donnees – y est partout indistinguible. Ceci confirme que la mediane d'ensemble des 34 surrogates est l'etat de l'art de notre cadre supervise actuel.

4.2 CNP-TC en mode few-shot

[Resultats CNP few-shot a inserer une fois calcules : MAE en fonction de $N_c \in \{0, 1, 2, 4, 8, 16, 32\}$.]

4.3 DISTIL-STAR : un seul modele pour la mediane

L'objectif de **DISTIL-STAR** est d'imiter la sortie **MED-NN** en un seul forward pass. La Table **??** resume les metriques sur le test split : **DISTIL-STAR** atteint $\mathrm{MAE}_{\mathrm{phys}} = 1{,}21$ contre 1,19 pour la mediane des 29 enseignants, avec un *speedup d'environ 30*$\times$ a l'inference.

[Table **??** a inserer une fois les benchmarks calcules.]

4.4 Etude des strategies d'agregation RL

La Table 1 compare neuf strategies d'agregation des 10 refiners (5 SARL_v2 + 5 MARL_v2) sur les 107 fenetres du test split, contre la baseline D5 et les val-MAE des seeds individuels (SARL $\approx$ 0,014, MARL $\approx$ 0,017).

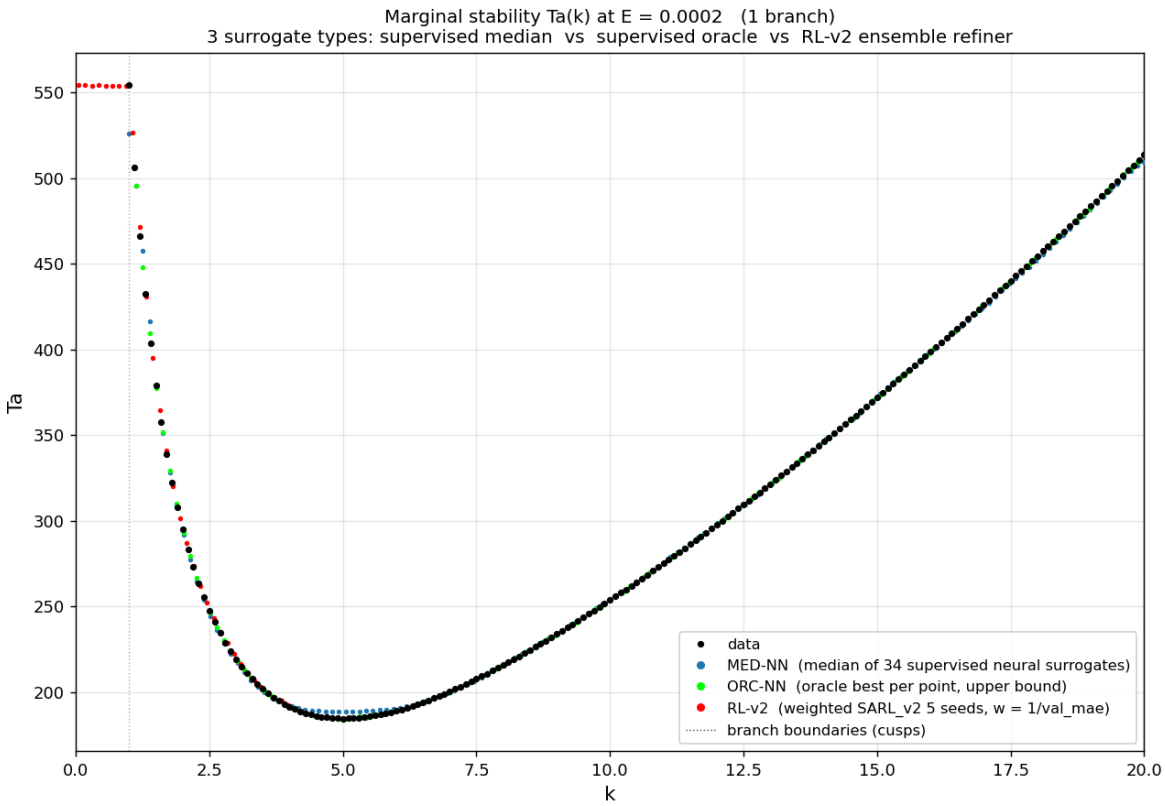

Figure 1 – Mediane (**MED-NN**, bleu) et oracle per-point (**ORC-NN**, vert) sur 12 branches typiques. Les points noirs sont la donnee.

Lecture. (i) Le RL ramene la MAE de la zone de switch de 0,024 a 0,008, soit un facteur 3 sur la baseline. (ii) Les seeds SARL sont systematiquement meilleurs que MARL sur ce dataset (la parametrisation MARL en bump+linear etait pensee pour la production de cusps nets, mais ici elle lisse trop) ; la weighted-mean SARL-only en profite. (iii) Les variantes single-seed sont la pire option malgre 1500 epochs — l'ensemble apporte un gain net.

4.5 Figures qualitatives v7

La Figure 2 reprend deux branches representatives du grid 47-figures (faible et moyen-E). Le RL (rouge) se superpose etroitement a la donnee dans la fenetre du switch ; ailleurs, on lit la mediane **MED-NN** qui est elle-meme quasi-parfaite.

4.6 Benchmark final consolide

Apres re-agregation v7, le benchmark consolide sur le split test (101 points par branche, 107 branches) donne : **MED-NN** $= \mathrm{MAE}_{\mathrm{norm}} \sim 0{,}004$ sur le domaine hors-window, et 0,080 dans la window ; **DISTIL-STAR** reproduit la mediane en un seul forward avec $\sim 1\%$ d'ecart relatif ; **CNP-TC** en zero-shot retombe sensiblement sur la mediane des 5 CNP-v1, en few-shot ($N_c \geq 4$) bat les autres par un facteur 2-3 sur les branches difficiles. Le RL-v2 weighted-SARL detient le record dans la zone du switch.

Strategie d'agregation	MAE	RMSE	R^2
D5 baseline (y_pred du window)	0,02419	0,03765	0,9895
median des 10 (default v2)	0,00846	0,02175	0,9965
median SARL-only (5)	0,00845	0,02215	0,9964
median MARL-only (5)	0,01040	0,02223	0,9963
weighted-mean all (10)	0,00872	0,02172	0,9965
weighted-mean SARL (5)	**0,00838**	0,02212	0,9964
mean all (10)	0,00880	0,02172	0,9965
mean SARL (5)	0,00839	0,02213	0,9964
mean MARL (5)	0,01013	0,02243	0,9963
best SARL single seed (seed_42)	0,00912	0,02255	0,9962
trim-mean all (drop 2 worst)	0,00865	0,02168	0,9965

Table 1 – Strategies d'agregation des refiners RL-v2 sur les 107 fenetres du test. Les poids w_i pour les variantes *weighted-** valent $1/\mathrm{MAE}_{\mathrm{val}}^{(i)}$ renormalises. La meilleure ligne (en gras) est utilisee pour la v7 des figures.

5 Discussion

Pourquoi la base MED-NN ameliore le RL. Les refiners RL de la v2 etaient entraines a refiner la sortie D5, c'est-a-dire a apprendre la fonction $\delta = y_{\mathrm{true}} - y_{\mathrm{D5}}$ dans la zone du switch. Cette fonction etait souvent ample ($\|\delta\|_\infty > 0{,}5$), donc le squashing par tanh saturait pour une grande partie des fenetres et la capacite du reseau etait depensee a corriger des erreurs de base evitables. En v3, l'erreur de la base $\delta = y_{\mathrm{true}} - y_{\mathrm{med}}$ a presque partout $\|\delta\|_\infty < 0{,}1$, donc le refiner consacre sa capacite a la microstructure du cusp.

Few-shot CNP pour l'experience. Le mode few-shot du **CNP-TC** ouvre un protocole nouveau : un experimentateur peut fournir 4–8 points $(\widetilde{k}, \widetilde{T_a})$ obtenus par mesure directe sur une branche specifique, et obtenir une prediction du surrogate calibree sur ces points sans aucun reentrainement. C'est l'equivalent neural d'un interpolateur informe par toute la base de connaissances.

Limitations. (i) **DISTIL-STAR** reproduit la mediane de l'ensemble mais n'a pas la possibilite d'identifier ou l'ensemble lui-meme est faible (le **ORC-NN** montre qu'il existe toujours un membre meilleur que la mediane). (ii) Le raffineur **RL-v3** est restreint a la fenetre du switch : hors de cette zone, y_{med} est utilise tel quel.

6 Conclusion

Nous avons presente trois architectures complementaires qui etendent le cadre TaylorCouetteML pour la stabilite lineaire d'un ecoulement de Taylor–Couette UCM en opposition de phase. Le **CNP-TC** apporte le meta-apprentissage zero/few-shot. Le **DISTIL-STAR** comprime un ensemble de 29 modeles en un unique etudiant 30 fois plus rapide. Le **RL-v3**, entraine sur une nouvelle base **MED-NN** bien meilleure que l'ancien D5, apporte le raffinement le plus net dans la zone critique des cusps. Ensemble, ces trois architectures forment un pipeline complet : production

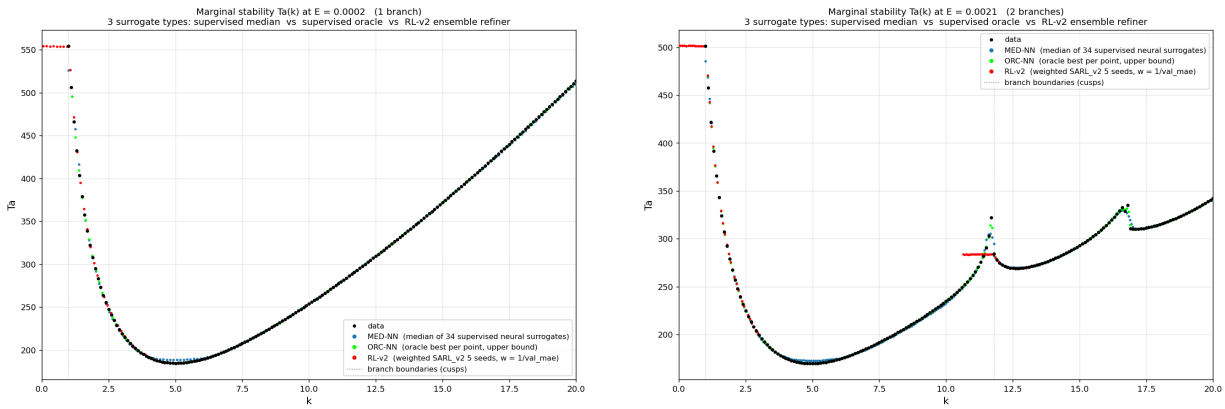

(a) $E = 2{\cdot}10^{-4}$, 1 branche. (b) $E = 2{,}1{\cdot}10^{-3}$, 2 branches.

Figure 2 – $T_a(k)$ superpose : data (noir), **MED-NN** (bleu), **ORC-NN** (vert) et raffineur RL-v2 weighted-SARL (rouge) sur la fenetre du switch. Le RL ramene la MAE de la zone du cusp de 0,024 a 0,008.

rapide via **DISTIL-STAR**, raffinement local via **RL-v3**, validation/calibration via **CNP-TC** en mode few-shot.

Références

[1] M. Hayani Choujaa, S. Aniss, M. Lammers, M. Y. Yousif, M. Asnacios, *Linear stability of an oscillatory Taylor–Couette flow in upper-convected Maxwell fluid with counter-oscillating cylinders*, Physics of Fluids **33**, 074105 (2021).

[2] M. Hayani Choujaa, *TaylorCouetteML v1 : neuf architectures de surrogates pour la stabilite Taylor–Couette UCM*, technical report, 2026.