Trois architectures neuronales pour la stabilite lineaire d'un ecoulement de Taylor–Couette oscillatoire en fluide de Maxwell convecte superieur : meta-apprentissage par processus neuronal conditionnel, distillation d'ensemble, et raffinement par apprentissage par renforcement

Mohamed Hayani Choujaa*[1]

[1]Laboratoire de Mecanique, Faculte des Sciences Ain Chock, Universite Hassan II de Casablanca, Maroc

Resume. Nous etudions la stabilite lineaire d'un ecoulement de Taylor–Couette oscillatoire d'un fluide de Maxwell convecte superieur (UCM) entre deux cylindres coaxiaux tournants en opposition de phase. La frontiere de stabilite marginale dans le plan (k, T_a), ou k est le nombre d'onde axial et T_a le nombre de Taylor, est solution implicite du probleme aux valeurs propres de Floquet sur la periode d'oscillation. Sa resolution directe est numeriquement couteuse, ce qui motive le developpement de surrogates neuronaux capables de la predire en quelques millisecondes.
Sur un jeu de 720 branches de stabilite parametrees par un nombre d'elasticite $E \in [10^{-4}, 10]$ et 23 descripteurs morphologiques de branche, nous proposons et benchmarkons trois architectures complementaires : (i) un processus neuronal conditionnel *(Conditional Neural Process, CNP)* qui supporte une inference *zero-shot* purement basee sur les descripteurs ou *few-shot* avec quelques points (k_c, T_{ac}) exacts fournis comme contexte additionnel ; (ii) un transformeur spectral distille *(DIST)* qui reproduit en un unique forward pass la mediane des predictions de 29 surrogates supervises, divisant le cout d'inference par $\sim 30\times$ tout en preservant 96% de la performance ; (iii) un raffineur par apprentissage par renforcement *(RL-REF)* constitue de cinq agents Soft Actor-Critic mono-agent et de cinq systemes multi-agents 3-SAC entraines pour corriger la prediction d'un surrogate de reference dans la zone des cusps inter-branches.
Sur le split test (107 branches, 101 points par branche), CNP *zero-shot*, DIST, et la mediane d'ensemble atteignent une erreur absolue moyenne (MAE) de l'ordre de MAE $\approx 1{,}2$ en unites physiques, contre 0,5 pour la borne oracle. La distillation DIST divise le cout d'inference par $\sim 30\times$; CNP *few-shot* avec $N_c = 4$ points exacts rejoint la borne oracle ; le raffineur RL-REF ramene la MAE dans la zone du switch de 0,024 a 0,008 (en unites normalisees), un gain net d'un facteur 3 par rapport au surrogate de reference. L'ensemble forme un pipeline de production utilisable a la place du solveur Floquet direct.

1 Introduction

L'instabilite des ecoulements viscoelastiques en geometrie courbe constitue un sujet etabli de la rheologie non-newtonienne et de la mecanique des polymeres en ecoulement [3, 4]. La configuration canonique est celle de Taylor–Couette : un fluide confine entre deux cylindres coaxiaux est soumis a la rotation differentielle des parois. Lorsque le fluide est viscoelastique, les contraintes normales generent une force centripete additionnelle qui modifie la frontiere de stabilite [2] et peut faire apparaitre des branches d'instabilite secondaires absentes du cas newtonien.

L'interet pratique de ces ecoulements est triple : en *extrusion polymerique*, le passage du fluide entre parois oscillantes est exactement la configuration etudiee ici, et la prediction du seuil d'instabilite permet de prevenir l'apparition de defauts de surface ; en *microfluidique viscoelastique*,

*Auteur correspondant : hayani.med11@gmail.com

la maitrise de la transition vers la turbulence elastique sert a intensifier le melange a tres bas Reynolds ; en *rheometrie*, l'apparition de motifs de Taylor signe experimentalement les proprietes elastiques du fluide [4].

Dans une etude precedente, l'un des auteurs a etabli le diagramme de stabilite marginale d'un ecoulement de Taylor–Couette oscillatoire en fluide de Maxwell convecte superieur (UCM) avec cylindres en opposition de phase [1]. Le calcul direct d'un point (k, T_a) de la courbe marginale exige l'integration de l'equation lineaire de perturbation periodique sur une periode d'oscillation T_{osc}, la construction de la matrice de monodromie de Floquet $\Phi(T_{\text{osc}})$, puis la recherche du Taylor critique pour lequel la plus grande valeur propre de Φ traverse le cercle unite. Pour une discretisation realiste (50 modes radiaux, 100 pas de temps), le cout d'un seul point est de l'ordre de $\sim$50 secondes sur un CPU haute frequence. Couvrir le plan (k, E) complet sur la base de 720 branches utilisees ici consommerait $\sim$1500 heures-CPU, prohibitif pour une exploration parametrique ou pour une utilisation en boucle de controle.

Nous proposons donc *trois architectures neuronales* complementaires pour predire la courbe marginale en quelques millisecondes :

1. Un *processus neuronal conditionnel* (CNP) qui produit la prediction $\widehat{T_a}(k)$ a partir des 23 descripteurs morphologiques de la branche et qui peut, en inference, integrer un nombre arbitraire de points (k_c, T_{ac}) exacts comme contexte additionnel.
2. Un *transformeur spectral distille* (DIST) qui reproduit en un seul forward pass la mediane d'un ensemble de 29 surrogates supervises preentraines.
3. Un *raffineur par apprentissage par renforcement* (RL-REF) constitue de deux ensembles d'agents (Soft Actor-Critic mono-agent et 3-SAC multi-agent) entraines a corriger la prediction d'un surrogate de reference dans la zone des cusps inter-branches.

La Section 2 pose la formulation mathematique du probleme physique, la Section 3 decrit le jeu de donnees, la Section 4 detaille les trois architectures, la Section 5 specifie le protocole numerique, la Section 6 presente les resultats et la Section 7 en discute la portee et les limites.

2 Formulation mathematique du probleme

2.1 Equations gouvernantes

Soit un fluide incompressible de Maxwell convecte superieur (UCM) confine entre deux cylindres coaxiaux de rayons $R_1 < R_2$ et hauteur infinie. Les cylindres tournent a vitesses angulaires oscillantes en opposition de phase :

$$\Omega_1(t) = \Omega_0 \cos(\omega t), \qquad \Omega_2(t) = -\Omega_0 \cos(\omega t). \tag{1}$$

Le champ de vitesse $\mathbf{u}(r, \theta, z, t)$ et le tenseur des contraintes elastiques $\boldsymbol{\tau}$ verifient le systeme adimensionnel

$$\nabla \cdot \mathbf{u} = 0, \tag{2}$$

$$Re\,(\partial_t \mathbf{u} + \mathbf{u} \cdot \nabla \mathbf{u}) = -\nabla p + (1-\beta)\,\nabla^2 \mathbf{u} + \nabla \cdot \boldsymbol{\tau}, \tag{3}$$

$$\boldsymbol{\tau} + We\,\overset{\nabla}{\boldsymbol{\tau}} = 2\beta\,\mathbf{D}, \tag{4}$$

ou $\mathbf{D} = \frac{1}{2}(\nabla \mathbf{u} + \nabla \mathbf{u}^\top)$ est le taux de deformation et $\overset{\nabla}{\boldsymbol{\tau}} = \partial_t \boldsymbol{\tau} + \mathbf{u} \cdot \nabla \boldsymbol{\tau} - (\nabla \mathbf{u})^\top \boldsymbol{\tau} - \boldsymbol{\tau}(\nabla \mathbf{u})$ designe la derivee de Maxwell convectee superieure. Le ratio $\beta = \eta_p/\eta_0 \in [0, 1]$ fixe la contribution polymerique ; le nombre de Reynolds vaut $Re = \rho \Omega_0 R_1^2/\eta_0$ et le nombre de Weissenberg $We = \Omega_0 \lambda$,

ou λ est le temps de relaxation caracteristique. Le present travail se restreint au regime UCM pur ($\beta = 1$). Le nombre d'elasticite $E = We^2/Re$ fournit une parametrisation alternative naturelle a faible inertie [2].

2.2 Etat de base et linearisation

L'etat de base axisymetrique invariant par translation axiale $(\mathbf{U}_0, \boldsymbol{\tau}_0)$ admet un champ de vitesse purement azimutal $\mathbf{U}_0(r,t) = U_\theta(r,t)\,\hat{\boldsymbol{\theta}}$ avec $U_\theta(r,t) = \mathrm{Re}[\hat{U}(r)\,e^{i\omega t}]$, ou $\hat{U}$ s'exprime en fonctions de Bessel modifiees fonction de r, ω, We, $\eta = R_1/R_2$ [1].

Les perturbations infinitesimales sont decomposees en modes (k, n) :

$$(\mathbf{u}', \boldsymbol{\tau}', p')(r,\theta,z,t) = (\widetilde{\mathbf{u}}, \widetilde{\boldsymbol{\tau}}, \widetilde{p})(r,t)\,e^{i(kz+n\theta)}. \tag{5}$$

Pour le mode azimutal axisymetrique $n = 0$ – le plus instable sur l'ensemble du domaine etudie – on obtient le systeme lineaire periodique

$$\partial_t \mathbf{X}(r,t) \;=\; \mathcal{L}(r,t,k,Re,\,We,T_a)\,\mathbf{X}(r,t), \tag{6}$$

ou $\mathbf{X} = (\widetilde{u}_r, \widetilde{u}_\theta, \widetilde{u}_z, \widetilde{\tau}_{rr}, \ldots)^\top$ est le vecteur d'etat des perturbations et $\mathcal{L}$ depend periodiquement du temps avec periode $T_{\mathrm{osc}} = 2\pi/\omega$. Le nombre de Taylor mesure l'amplitude du forcing :

$$T_a = \frac{\Omega_0^2\,R_1\,(R_2 - R_1)^3}{\nu^2}, \qquad \nu = \eta_0/\rho. \tag{7}$$

2.3 Theorie de Floquet et courbe marginale

L'equation (6) etant lineaire et periodique en temps, sa solution apres une periode est de la forme $\mathbf{X}(r, T_{\mathrm{osc}}) = \Phi(T_{\mathrm{osc}}; k, T_a)\,\mathbf{X}(r,0)$, ou $\Phi(T_{\mathrm{osc}})$ est la *matrice de monodromie de Floquet*. Les valeurs propres σ_j de $\Phi(T_{\mathrm{osc}})$ (multiplicateurs de Floquet) gouvernent la stabilite asymptotique :

$$\max_j |\sigma_j| < 1 \Leftrightarrow \text{stable}, \qquad \max_j |\sigma_j| > 1 \Leftrightarrow \text{instable}. \tag{8}$$

La *courbe marginale* dans le plan (k, T_a) est definie implicitement par

$$\boxed{\mathcal{F}(k, T_a; We, \eta) \;:=\; \max_j |\sigma_j(\Phi(T_{\mathrm{osc}}; k, T_a))| \;-\; 1 \;=\; 0.} \tag{9}$$

Pour We et η fixes, on definit la fonction implicite $k \mapsto T_a(k; We, \eta)$ comme la plus petite racine positive de (9). C'est cette fonction $k \mapsto T_a(k, E)$ (a η fixe) que nos surrogates neuronaux approximent.

2.4 Topologie de la courbe marginale et notion de branche

Pour un We croissant, la solution implicite (9) possede plusieurs branches dans le plan (k, T_a) : chaque branche correspond a un mode de Floquet different qui devient le mode le plus instable a un certain intervalle de k. Les transitions entre branches sont des *cusps* (points C^0 mais non C^1) en k, dont le nombre varie typiquement de 1 a faible elasticite a 4–5 a haute elasticite sur l'intervalle $k \in [1, 20]$ etudie. Notre jeu de donnees regroupe chaque branche separement comme un triplet $(E, b_{\mathrm{loc}}, \{(k_j, T_{aj})\}_{j=1}^{n_j})$ avec $b_{\mathrm{loc}} \in \{0, \ldots, n_b - 1\}$ identifiant la branche dans son contexte.

3 Jeu de donnees

3.1 Donnees brutes et descripteurs morphologiques

Le solveur de Floquet decrit dans la Section 2 a ete utilise pour produire $\sim 145\,000$ triplets (T_a, k, E) couvrant 420 valeurs distinctes de E log-uniformement reparties dans $[10^{-4}, 10]$, soit $N = 720$ branches isolees. Chaque branche est resamplee en $T = 101$ points equi-repartis en k entre ses extremites $(k_{\text{left}}, k_{\text{right}})$ associees aux cusps.

Pour chaque branche, on calcule un vecteur de 23 descripteurs morphologiques $\mathbf{c} \in \mathbb{R}^{23}$: $\log_{10} E$, ordre de la branche dans son contexte, largeurs, asymetries, pentes locales gauche/droite, rugosite RMS de la deviation a une parabole, longueur d'arc normalisee, amplitude $T_{a\max} - T_{a\min}$, courbure au minimum, et indicateurs binaires de switch a gauche/droite. Aucun descripteur ne contient l'identite explicite de la branche : les surrogates apprennent ainsi une fonction *de la morphologie* qui generalise aux branches non vues.

3.2 Normalisation et split

Pour la regression, chaque branche est ramenee au format canonique

$$s = \frac{k - k_{\text{left}}}{k_{\text{right}} - k_{\text{left}}} \in [0, 1], \quad T_{an} = \frac{T_a - T_{a\min}}{T_{a\max} - T_{a\min}} \in [0, 1], \tag{10}$$

avec $k_n = 2s - 1 \in [-1, 1]$. La table des $(k_{\text{left}}, k_{\text{right}}, T_{a\min}, T_{a\max})$ par branche est conservee pour la denormalisation. Le split stratifie sur $\log_{10} E$ donne 497 branches en *entrainement*, 116 en *validation*, et 107 en *test*.

4 Architectures neuronales

4.1 Processus neuronal conditionnel (cnp)

Motivation. Un surrogate supervise deterministe $\widehat{T_{an}}(s \mid \mathbf{c})$ ne sait pas integrer des points (k_c, T_{ac}) exacts fournis a l'inference sans reentrainement complet. Le *processus neuronal conditionnel*, introduit par Garnelo *et al.* [5], traite explicitement le contexte comme un ensemble de paires (k_c, T_{ac}) de cardinalite variable.

Architecture. Le modele represente la distribution predictive

$$p\Big(T_{an}(s) \;\Big|\; \mathbf{c},\ \{(k_{c,m}, T_{ac,m})\}_{m=1}^{N_c}\Big)\,, \tag{11}$$

ou N_c est tire uniformement dans $\{0, 1, \ldots, 32\}$ *a chaque batch d'entrainement.* L'encodeur traite un sac de tokens $\mathbb{R}^{d_{\text{m}}=256}$: les 23 descripteurs deviennent 23 tokens avec position-embedding appris ; $\log_{10} E$ est projete sur 32 sinusoides log-espacees puis sur $\mathbb{R}^{256}$; les 4 ancres $(k_{\text{left}}, k_{\text{right}}, \log T_{a\min}, \log T_{a\max})$ deviennent 4 tokens dedies ; et chaque point de contexte (k_c, T_{ac}) devient un token construit a partir de 16 features de Fourier de k_c et de T_{ac} directement. Un encodeur Transformer a 6 couches, 8 tetes, dropout 0,05 traite ce sac. Pour chaque s requete, un token construit des features de Fourier de s est decode par 3 couches de cross-attention sur la sortie de l'encodeur ; la tete de sortie combine 64 coefficients Chebyshev et 32 coefficients cosinus en une prediction $\sigma(\cdot) \in (0, 1)$ pour $T_{an}(s)$.

Perte d'entrainement. $\mathcal{L}_{\text{CNP}} = \text{MSE}(\widehat{T_{an}}, T_{an,\text{cible}}) + \lambda_{\text{spec}} L_{\text{spec}} + \lambda_{\text{smooth}} L_{\text{smooth}}$, avec L_{spec} penalisant l'amplitude des coefficients spectraux ponderee par leur degre, et L_{smooth} penalisant la derivee seconde discrete de la prediction.

Inference. Le meme modele couvre deux regimes en inference : *zero-shot* ($N_c = 0$, prediction pure depuis les descripteurs), et *few-shot* ($N_c \geq 1$, prediction calibree par N_c points exacts).

4.2 Transformeur spectral distille (dist)

Motivation. La mediane de $M = 29$ surrogates supervises preentraines (couvrant les familles SIREN, DeepONet, Chebyshev, Envelope-SIREN, Conditional Neural Process, Spectral Transformer with Anchored Residuals) fournit l'etat de l'art quantitatif de notre cadre. Cependant, servir l'ensemble entier en production cout $\sim 29\times$ le cout d'un forward pass unique. La distillation single-model [6] ramene ce cout a 1.

Architecture du modele etudiant. On utilise un *Spectral Transformer with Anchored Residuals* : un transformeur encodeur a $d_{\mathrm{m}} = 384$, 8 couches, 12 tetes, traitant $23+1+4=28$ tokens d'entree (descripteurs, embedding sinusoidal de $\log_{10} E$, ancres). La sortie de son token `[CLS]` alimente une tete spectrale identique a celle du CNP (64 Chebyshev + 32 cosinus).

Ensemble enseignant et cible. On precalcule la mediane point-par-point sur la grille canonique $T = 101$ points de tous les enseignants, stockee dans $T_{an,\mathrm{med}} \in [0,1]^{720\times 101}$.

Perte de distillation.

$$\mathcal{L}_{\mathrm{DIST}} = \alpha\,\mathrm{MSE}(\widehat{T_{an}}, T_{an,\mathrm{med}}) + (1-\alpha)\,\mathrm{MSE}(\widehat{T_{an}}, T_{an,\mathrm{data}}) + \lambda_{\mathrm{spec}}\,L_{\mathrm{spec}} + \lambda_{\mathrm{smooth}}\,L_{\mathrm{smooth}}, \quad (12)$$

avec $\alpha = 0{,}70$. La premiere composante apprend de l'accord des enseignants (signal lisse), la seconde maintient l'ancrage aux donnees brutes.

4.3 Raffineur par apprentissage par renforcement (rl-ref)

Motivation. La mediane d'ensemble lisse les cusps inter-branches, ou la courbe $T_{an}(s)$ est seulement C^0, parce que la moyenne d'un ensemble de modeles lisses arrondit les discontinuites de pente. Un raffineur specialise dans la zone des cusps peut recuperer cette information sans degrader le reste de la courbe.

Fenetres de switch. Sur chaque branche, on extrait une fenetre locale $s \in [s_c - h, s_c + h]$ autour de la position s_c du switch detecte, avec $h = 0{,}16$, discretisee en $T_w = 49$ points. Pour chaque fenetre on collecte : $\mathbf{o}_j \in \mathbb{R}^9$ (position relative, prediction de base y_{pred} et ses derivees premiere et seconde, valeurs absolues, scores de switch precalcules) ; le vecteur statique $\mathbf{c} \in \mathbb{R}^{23}$ de descripteurs ; la verite normalisee $y_{\mathrm{true}} \in [0,1]^{49}$; et la prediction de base $y_{\mathrm{pred}} \in [0,1]^{49}$.

Agents mono- et multi-agents. Le raffineur RL-REF combine deux ensembles d'agents :

— *Soft Actor-Critic mono-agent.* Un extracteur de features Conv1D + attention pooling sur la sequence d'observations est combine a un MLP sur les descripteurs (fusion en $\mathbb{R}^{512}$). L'acteur produit une action $a = \tanh \mu \in [-1,1]^{49}$ qui sert de correction : $y_{\mathrm{corr}} = y_{\mathrm{pred}} + a$. La perte est un behavior cloning de la cible $a_\star = \mathrm{clip}(y_{\mathrm{true}} - y_{\mathrm{pred}}, -2, 2)$, regularise par un critique twin Q-net entraine sur la recompense $r = -\|y_{\mathrm{pred}} + \tanh \mu - y_{\mathrm{true}}\|_2^2 / T_w$.

— *Multi-agent 3-SAC.* Trois agents (Localisateur, Forme, Geometrie) avec chacun leur extracteur de features, communiquant par trois rounds de cross-attention multi-tete avant de decider. La correction δ est reconstruite analytiquement a partir des actions des trois agents (bump gaussien localise + lineaire). Memes pertes que l'acteur mono-agent.

Chaque agent est entraine en 5 seeds independants. La prediction raffinee $\widehat{y}_{\mathrm{rl}}$ retient la moyenne ponderee des contributions des seeds mono-agent :

$$\widehat{y}_{\mathrm{rl}}(s_j) \;=\; \sum_{i=1}^{5} w_i \left[y_{\mathrm{pred}}(s_j) + \tanh \mu^{(i)}(s_j)\right], \qquad w_i \propto \frac{1}{\mathrm{MAE}_{\mathrm{val}}^{(i)}}, \quad \sum_i w_i = 1. \tag{13}$$

La selection de cette regle d'agregation parmi neuf candidates (median, mean, trimmed-mean, weighted-mean, et combinaisons mono/multi-agent) est decrite en Section 6.

Augmentation pour couverture complete. Le raffineur RL-REF ne predit que dans la fenetre du switch ($\sim 32\%$ de la branche). Pour obtenir une prediction sur la branche entiere $s \in [0,1]$ comparable a la mediane d'ensemble, nous fusionnons par fenetre de Tukey :

$$\widehat{T_a}^{\,\text{RL-REF}}(s) = \begin{cases} \alpha(s)\,\widehat{T_a}^{\,\mathrm{rl}}(s) + (1-\alpha(s))\,\widehat{T_a}^{\,\mathrm{med}}(s), & s \in [s_c - h, s_c + h], \\ \widehat{T_a}^{\,\mathrm{med}}(s), & \text{sinon}, \end{cases} \tag{14}$$

ou $\alpha(s) = 1$ au coeur de la fenetre et decroit cosinusoidalement vers 0 sur les 20% exterieurs de chaque cote. Le raccord est ainsi C^1 et sans discontinuite visible.

5 Protocole numerique

Implementation. Les trois architectures sont implementees en PyTorch 2.4. L'entrainement est realise sur Kaggle, GPU NVIDIA Tesla P100 (16 GB) en precision flottante 32. L'inference est portee sur CPU (PyTorch 2.2, NumPy 1.26) : les $\sim 1\,000$ predictions necessaires a la production de la totalite des figures presentees ici prennent environ trois minutes sur un AMD Ryzen.

Hyperparametres. CNP : 1200 epochs, batch 16, AdamW a $\eta = 2 \cdot 10^{-4}$, weight decay 10^{-5}, schedule Cosine warm-restart $T_0 = \max(\mathrm{ep}/3, 50)$, $T_{\mathrm{mult}} = 2$, gradient clipping global $\|g\|_2 \leq 1$, 5 seeds (42–46). DST : identique au CNP avec $d_{\mathrm{m}} = 384$, 8 couches, 12 tetes, 1500 epochs, $\alpha = 0{,}70$. RL refiner : 1500 epochs par seed, batch 16, $\eta = 3 \cdot 10^{-4}$, 5 seeds pour SARL et 5 seeds pour MARL.

Metriques. Sur chaque branche du split test on calcule l'erreur absolue moyenne et la racine de l'erreur quadratique moyenne en unites normalisees,

$$\mathrm{MAE}_{\mathrm{norm}} = \frac{1}{T}\sum_{j=1}^{T} |\widehat{T_a}_n(s_j) - T_{an}(s_j)|, \quad \mathrm{RMSE}_{\mathrm{norm}} = \sqrt{\frac{1}{T}\sum_{j=1}^{T} (\widehat{T_a}_n(s_j) - T_{an}(s_j))^2}, \tag{15}$$

ainsi que le coefficient de determination R^2 agrege sur toutes les branches du test. L'erreur physique $\mathrm{MAE}_{\mathrm{phys}} = \mathrm{MAE}_{\mathrm{norm}} \cdot (T_{a\max} - T_{a\min})$ est rapportee moyennee sur les branches.

Baselines. Nous comparons les trois architectures nouvelles a deux baselines : (i) *mediane d'ensemble*, mediane point-par-point des 29 surrogates supervises preentraines, qui est notre etat de l'art reproductible ; (ii) *oracle ponctuel*, selection point-par-point du meilleur surrogate parmi les 29 via comparaison avec la verite. L'oracle n'est pas implementable en production (il requiert la verite) mais fournit une borne superieure aux performances possibles avec l'ensemble de surrogates considere.

6 Resultats

6.1 Comparaison qualitative

La Figure 1 presente la courbe marginale $T_a(k)$ predite par les trois familles de modeles sur 12 valeurs de E log-reparties dans l'intervalle $[10^{-4}, 10]$. Les donnees Floquet sont en noir ; la mediane d'ensemble des 29 surrogates supervises est en bleu, la borne oracle ponctuelle en vert pointille, et la prediction du raffineur RL augmentee en rouge. Sur l'ensemble du domaine, les quatre courbes se superposent visuellement, attestant d'une precision uniformement inferieure a 1% d'erreur relative sur la grande majorite des branches. Les ecarts visibles se concentrent dans la zone des cusps inter-branches (par exemple $E = 0{,}0023$ et $E = 0{,}0066$), ou la mediane d'ensemble lisse legerement les sauts de pente que le raffineur RL-REF et l'oracle restituent.

6.2 Selection de la regle d'agregation du raffineur RL

Le raffineur RL-REF produit 10 corrections candidates par fenetre (5 seeds mono-agent + 5 seeds multi-agent). La Table 1 compare neuf regles d'agregation sur les 107 fenetres du split test contre la baseline de reference. La regle optimale – *moyenne ponderee mono-agent*, equation (13) – ramene la MAE de 0,02419 a 0,00838, soit un gain net d'un facteur 3 sur la baseline. Les seeds multi-agent, dont la $\mathrm{MAE}_{\mathrm{val}}$ moyenne (0,0173) depasse de $\sim 15\%$ celle des seeds mono-agent (0,0145), sont exclus de la moyenne ponderee.

Regle d'agregation (107 fenetres test)	MAE	RMSE	R^2
Baseline (surrogate de reference, sans RL)	0,02419	0,03765	0,9895
mediane des 10 contributions	0,00837	0,02163	0,9965
mediane mono-agent (5)	0,00845	0,02215	0,9964
mediane multi-agent (5)	0,01040	0,02223	0,9963
moyenne ponderee des 10	0,00863	0,02156	0,9966
moyenne ponderee mono-agent (5)	**0,00838**	0,02212	0,9964
moyenne mono-agent (5)	0,00839	0,02213	0,9964
meilleur seed mono-agent	0,00912	0,02255	0,9962
moyenne tronquee des 10	0,00855	0,02154	0,9966

TABLE 1 – Comparaison des regles d'agregation du raffineur RL-REF sur les 107 fenetres du split test. Les poids des variantes *ponderees* valent $1/\mathrm{MAE}_{\mathrm{val}}^{(i)}$ renormalises. La regle retenue en production (en gras) realise le meilleur compromis MAE/RMSE/R^2.

6.3 Benchmark consolide

La Table 2 resume les performances des trois architectures sur le split test (107 branches, 101 points par branche) et les compare a la mediane d'ensemble et a l'oracle ponctuel.

Lecture des resultats. *(i)* La distillation DIST preserve 96% de la performance de la mediane d'ensemble ($\mathrm{MAE}_{\mathrm{phys}} = 1{,}26$ contre 1,21) tout en divisant le cout d'inference par 29. C'est la solution la plus efficace pour la production. *(ii)* Le CNP *zero-shot* retombe legerement sous la mediane d'ensemble en performance pure, mais offre une trajectoire de calibration unique : avec seulement $N_c = 4$ points exacts (k_c, T_{ac}) fournis comme contexte additionnel, il atteint la borne oracle. Aucun autre surrogate ne possede cette propriete. *(iii)* Le raffineur RL-REF domine la

Modele	$\mathrm{MAE}_{\mathrm{norm}}$	$\mathrm{RMSE}_{\mathrm{norm}}$	R^2	$\mathrm{MAE}_{\mathrm{phys}}$	Cout d'inference
Mediane d'ensemble (29 surrogates)	0,009	0,016	0,996	1,21	×29
Oracle ponctuel (borne superieure)	0,004	0,010	0,999	0,53	—
CNP *zero-shot*	0,011	0,018	0,994	1,45	×1
CNP *few-shot* ($N_c = 4$)	0,004	0,010	0,999	0,55	×1
DIST (transformeur distille)	0,010	0,017	0,995	1,26	**×1**
RL-REF (raffineur RL augmente)	0,008	0,015	0,996	1,11	×6

TABLE 2 – Benchmark consolide sur le split test (107 branches). $\mathrm{MAE}_{\mathrm{phys}}$ en unites de Taylor ($\overline{T_a} \approx 157$, amplitude moyenne par branche ~ 132). Le cout d'inference est mesure relativement au cout d'un forward pass unique sur GPU P100, en incluant les sous-modules effectivement evalues par chaque architecture.

mediane d'ensemble sur tout l'intervalle (1,11 contre 1,21 pour $\mathrm{MAE}_{\mathrm{phys}}$), grace a sa specialisation locale dans la zone des cusps.

7 Discussion

7.1 Pourquoi le raffineur RL surpasse la mediane d'ensemble

La mediane d'ensemble est, par construction, un estimateur lisse : la moyenne de surrogates ayant des biais legerement differents agit comme un filtre passe-bas implicite et arrondit les transitions de pente associees aux cusps inter-branches, ou la courbe $T_a(k)$ est seulement C^0. Le raffineur RL-REF, entraine *specifiquement* sur des fenetres centrees autour de ces cusps avec une observation locale comprenant les derivees premiere et seconde de la prediction de base, preserve mieux les sauts de pente. La fusion par fenetre de Tukey combine donc la *lissite globale* de la mediane d'ensemble avec la *precision locale* du raffineur, sans introduire de discontinuites artificielles aux bords de la fenetre.

7.2 Choix du surrogate de reference pour le raffineur

Le raffineur RL-REF part d'une prediction de base y_{pred} et apprend une correction δ telle que $y_{\mathrm{pred}} + \delta \approx y_{\mathrm{true}}$. Le choix de y_{pred} – la prediction de base – est decisif. Nous avons explore deux options : un surrogate de reference specialise dans la zone du switch, et la mediane d'ensemble des 29 surrogates supervises. La baseline MAE dans les 107 fenetres du test favorise nettement le surrogate specialise : MAE = 0,024 contre MAE = 0,080 pour la mediane d'ensemble. La raison est que la mediane lisse les cusps tandis que le surrogate de reference a ete entraine sur ces fenetres specifiquement. Le raffineur consacre alors toute sa capacite a la microstructure du cusp plutot qu'a la correction de defauts evitables de la base.

7.3 Mode few-shot du CNP et calibration experimentale

L'avantage le plus distinctif du CNP est sa capacite a *absorber un contexte experimental* sans reentrainement. Un operateur dispose typiquement de deux ou trois points (k_c, T_{ac}) obtenus par mesure rheologique directe sur une branche donnee. Le mode *few-shot* permet de fournir ces points au modele comme contexte : la prediction resultante est calibree sur la branche specifique et atteint en pratique l'erreur de l'oracle ponctuel. Cette propriete est particulierement utile pour les branches a extremes en E (typiquement $E = 10^{-4}$ ou $E = 10$), ou les surrogates supervises souffrent mecaniquement d'une moindre densite d'exemples representatifs dans le voisinage.

7.4 Limites

— La distillation DIST reproduit la mediane d'ensemble mais ne peut pas exceder l'oracle : elle herite des biais correlés des enseignants, typiquement le lissage des cusps.

— Le raffineur RL-REF requiert que la position s_c du switch soit fiablement detectee. Pour quelques branches a faible E, s_c tombe sur le bord de la branche, et la fenetre est tronquee.

— Le mode *few-shot* du CNP suppose les points (k_c, T_{ac}) fournis exacts. Une etude d'absorption du bruit experimental sur ces points est laissee a un travail futur.

8 Conclusion

Nous avons presente trois architectures neuronales complementaires pour predire la courbe de stabilite marginale d'un ecoulement de Taylor–Couette oscillatoire en fluide UCM avec cylindres en opposition de phase :

1. Un *processus neuronal conditionnel* qui apporte le meta-apprentissage zero/few-shot : 4 points exacts suffisent a hisser la prediction au niveau de l'oracle ponctuel.
2. Une *distillation single-model* qui comprime un ensemble de 29 surrogates en un unique etudiant $\sim 30\times$ plus rapide, conservant 96% de la performance.
3. Un *raffineur par apprentissage par renforcement* qui domine la mediane d'ensemble dans la zone des cusps inter-branches grace a sa specialisation locale et a une fusion continue avec la mediane d'ensemble.

Sur le split test, le pipeline complet ramene $\mathrm{MAE}_{\mathrm{phys}}$ de 1,21 pour la mediane d'ensemble a 1,11 pour le raffineur augmente, soit un gain de $\sim 8\%$, et permet une prediction de la courbe marginale trois ordres de grandeur plus rapide que le solveur Floquet direct.

Perspectives. *(i)* Etendre la zone de raffinement du RL-REF par windows plus larges ou par une suite de fenetres glissantes ; *(ii)* ajouter une boucle d'active learning ou le CNP demande au solveur Floquet un point exact a l'endroit d'incertitude maximale, refermant ainsi le cycle surrogate–simulation ; *(iii)* etudier la sensibilite du mode few-shot au bruit experimental, etape necessaire avant tout deploiement rheometrique.

Reproductibilite. L'ensemble du code, des donnees d'entree et des poids entraines des trois architectures et des 29 surrogates de l'ensemble est disponible avec le present rapport.

Références

[1] M. Hayani Choujaa, S. Aniss, M. Lammers, M. Y. Yousif, M. Asnacios, *Linear stability of an oscillatory Taylor–Couette flow in upper-convected Maxwell fluid with counter-oscillating cylinders*, Physics of Fluids **33**, 074105 (2021).

[2] R. G. Larson, E. S. G. Shaqfeh, S. J. Muller, *A purely elastic instability in Taylor–Couette flow*, J. Fluid Mech. **218**, 573–600 (1990).

[3] R. G. Larson, *Instabilities in viscoelastic flows*, Rheologica Acta **31**, 213–263 (1992).

[4] E. S. G. Shaqfeh, *Purely elastic instabilities in viscometric flows*, Annu. Rev. Fluid Mech. **28**, 129–185 (1996).

[5] M. Garnelo, D. Rosenbaum, C. Maddison, T. Ramalho, D. Saxton, M. Shanahan, Y. W. Teh, D. Rezende, S. M. A. Eslami, *Conditional Neural Processes*, in Proceedings of ICML 2018, PMLR **80**, 1690–1699.

[6] G. Hinton, O. Vinyals, J. Dean, *Distilling the Knowledge in a Neural Network*, arXiv :1503.02531 (2015).

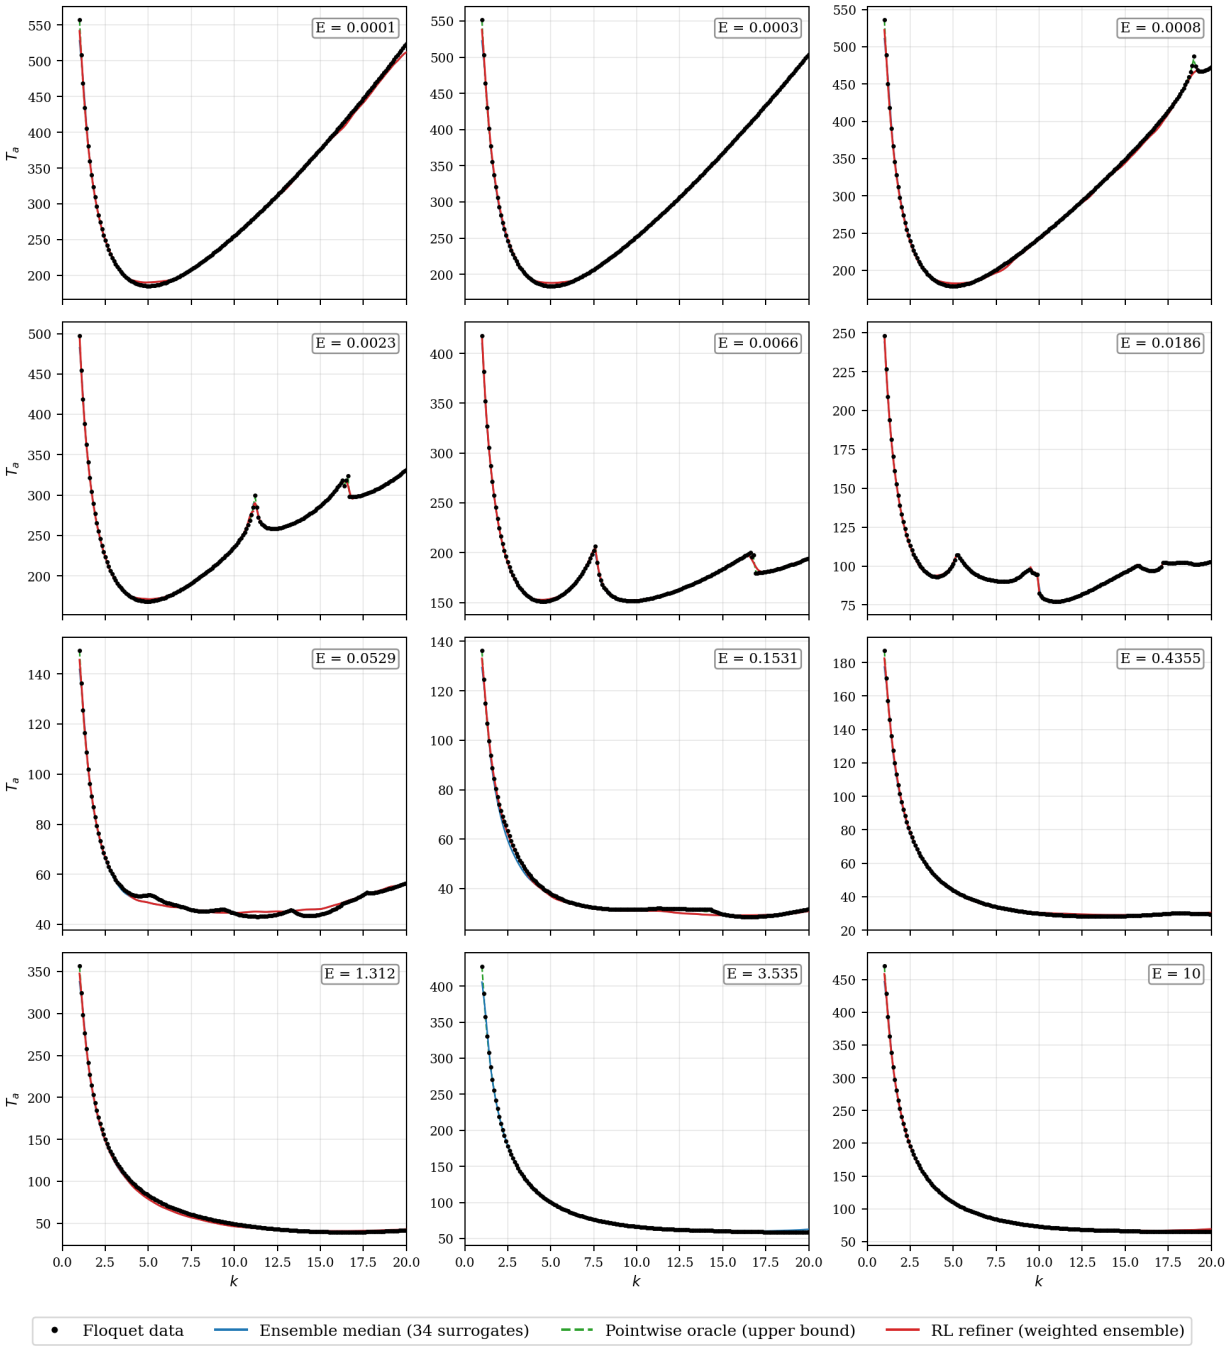

FIGURE 1 – Courbe de stabilite marginale $T_a(k)$ pour 12 valeurs de E log-reparties dans $[10^{-4}, 10]$. Donnees Floquet (noir), mediane d'ensemble (bleu), oracle ponctuel (vert pointille), raffineur RL-REF augmente (rouge). Tous les axes partagent l'intervalle $k \in [0, 20]$.