Surrogates neuronaux pour la stabilité linéaire d'un écoulement oscillatoire de Taylor–Couette d'un fluide de Maxwell sur-convecté

Présentation de neuf architectures

Mohamed Hayani Choujaa

8 mai 2026

Résumé

Nous présentons neuf modèles d'apprentissage supervisé entraînés à prédire la courbe de stabilité marginale $T_a(k, E)$ d'un écoulement oscillatoire de Taylor–Couette entre cylindres contre-oscillants pour un fluide viscoélastique de type Maxwell sur-convecté (UCM). La référence est un problème aux valeurs propres de Floquet à 720 branches indexées par le nombre d'élasticité $E \in [10^{-4}, 10]$ et 23 descripteurs fonctionnels. Les architectures couvrent transformers à mélange d'experts épars, opérateurs neuronaux (FNO + diffusion latente), refiners par apprentissage par renforcement (SAC, multi-agents SAC, MARL à politique de diffusion), représentations neuronales implicites (SIREN), apprentissage d'opérateurs branche-tronc (DeepONet), régression spectrale de Chebyshev, et un *Multi-Mode Envelope SIREN* qui encode la structure de croisement des modes Floquet. L'enveloppe SIREN atteint $\mathrm{MAE}_{\mathrm{phys}} = 0{,}549$ sur les données d'entrée originales, soit un gain $\times 2{,}4$ par rapport à la *baseline* historique.

1. Cadre physique et problème de Floquet

L'écoulement est la perturbation d'un profil de base unidimensionnel $\boldsymbol{U}_0(r,t) = U_b(r)\cos(\omega t)\,\hat{\boldsymbol{e}}_\theta$ entre deux cylindres infinis et concentriques contre-oscillant à la pulsation ω. La stabilité linéaire est gouvernée par l'équation constitutive de Maxwell sur-convectée,

$$\boldsymbol{\tau} + \lambda\Big(\partial_t \boldsymbol{\tau} + \boldsymbol{u}\cdot\nabla\boldsymbol{\tau} - (\nabla\boldsymbol{u})\boldsymbol{\tau} - \boldsymbol{\tau}(\nabla\boldsymbol{u})^\top\Big) = 2\mu\,\boldsymbol{D}(\boldsymbol{u}), \tag{1}$$

couplée aux équations de la quantité de mouvement et d'incompressibilité. Après linéarisation autour de $\boldsymbol{U}_0$, développement spectral radial sur la base de Chebyshev et décomposition de Floquet en temps $\hat{\phi}(r,t) = e^{\sigma t}\sum_n \tilde{\phi}_n(r)\,e^{in\omega t}$, le problème devient un problème aux valeurs propres généralisé

$$\boldsymbol{A}(k, T_a, E)\,\hat{\boldsymbol{\phi}} \;=\; \sigma\,\boldsymbol{B}(k,E)\,\hat{\boldsymbol{\phi}}, \qquad \sigma = \sigma_r(T_a,k,E) + i\,\sigma_i. \tag{2}$$

La courbe de stabilité marginale est le lieu $\sigma_r(T_a,k,E) = 0$ pour le mode Floquet le plus instable. Plusieurs modes pouvant être en compétition, la courbe possède une structure d'enveloppe inférieure

$$\boxed{T_a(k,E) \;=\; \min_{m=1,\dots,M} T_m(k,E)} \tag{3}$$

qui produit des cusps régulier-par-morceaux aux valeurs où l'indice du mode actif change.

2. Données

Source. Le fichier `combined`$_d ata.csvcontient$`122 820`$triplets$`(T`$_a, k, E)$ `obtenus en balayant le solveur Floquet, donnant` 720 `branches segmentées sur` 420 `valeurs uniques de` E.

Descripteurs. Pour chaque branche on extrait un vecteur de 23 caractéristiques $\boldsymbol{\xi} \in \mathbb{R}^{23}$ résumant la géométrie locale (largeurs, pentes, asymétries, courbure au minimum, longueur d'arc, indicateurs de switch, etc.) auxquelles on ajoute $\log_{10} E$ pour obtenir le contexte $\boldsymbol{\xi} \in \mathbb{R}^{24}$ fourni à chaque modèle.

Découpages. Découpage stratifié 70/15/15 sur $\log_{10} E$ avec huit quantiles, donnant 504/112/104 branches.

3. Architectures

3.1. Switch-Segment Sparse Transformer

Transformer à blocs Mixture-of-Experts épars. Pour chaque segment d'entrée $\boldsymbol{h} \in \mathbb{R}^{T \times d}$, un routeur calcule les affectations top-k aux experts

$$g_i(\boldsymbol{h}) = \mathrm{Softmax}_{\texttt{top-}k}(\boldsymbol{W}_g \boldsymbol{h})_i, \qquad \boldsymbol{h}' = \sum_{i=1}^{N} g_i(\boldsymbol{h})\, E_i(\boldsymbol{h}), \tag{4}$$

où les E_i sont des MLP. Avec $N = 8$ experts et $k = 2$ actifs par token, et 49M paramètres, ce modèle domine la famille transformer tout en gardant un coût d'inférence borné.

3.2. Fourier Neural Operator + diffusion latente

Un FNO 1D implémente le bloc spectral

$$\mathcal{F}^{-1}\big(\boldsymbol{R}_\theta \cdot \mathcal{F}(\boldsymbol{v})\big)(k) \;+\; \boldsymbol{W}\boldsymbol{v}(k), \tag{5}$$

où $\boldsymbol{R}_\theta$ est un multiplicateur complexe appris tronqué aux $M_F = 32$ modes basse fréquence, et $\boldsymbol{W}$ une convolution 1×1. Une tête de diffusion latente entraînée par denoising score matching échantillonne des corrections résiduelles via DDIM en $S = 50$ pas.

3.3. Refiner SAC mono-agent (Conv1D + AttnPool)

Un agent Soft Actor-Critic observe la *baseline* sur une fenêtre de 49 points. La politique $\pi_\phi(a \mid s)$ est une gaussienne écrasée par tanh, et l'apprentissage maximise le retour entropie-régularisé

$$J(\phi) = \mathbb{E}_{(s,a)\sim\rho_\pi}\Big[\, Q_\theta(s,a) - \alpha \log \pi_\phi(a \mid s) \,\Big], \tag{6}$$

avec température entropique α adaptée automatiquement. L'extraction de caractéristiques utilise une pile de convolutions 1D suivie d'un *attention pooling*.

3.4. 3-SAC MARL avec Cross-Attention

Trois agents SAC se spécialisent sur *location*, *shape* et *geometry* de la correction. Ils partagent leurs observations via un bloc d'attention croisée

$$\mathrm{CrossAttn}(\boldsymbol{Q}_i, \boldsymbol{K}, \boldsymbol{V}) = \mathrm{Softmax}\Big(\tfrac{\boldsymbol{Q}_i \boldsymbol{K}^\top}{\sqrt{d}}\Big)\boldsymbol{V} \tag{7}$$

qui couple les agents tout en préservant des politiques hétérogènes.

3.5. MARL à politique de diffusion (HYDRA, 7 agents)

Système multi-agents à 7 agents (manager, détecteur, asymétrie, géométrie, forme, lissité, validateur). La politique de chaque agent est un processus de débruitage par diffusion

$$\boldsymbol{a}^{(t-1)} = \tfrac{1}{\sqrt{\alpha_t}}\Big(\boldsymbol{a}^{(t)} - \tfrac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\,\epsilon_\theta(\boldsymbol{a}^{(t)}, t, \boldsymbol{m})\Big) + \sigma_t \boldsymbol{z}_t, \tag{8}$$

conditionnée par les messages inter-agents $\boldsymbol{m}$ produits par un Graph Attention Network (GAT). Critique centralisée + exécution décentralisée selon le schéma MAPPO ; algorithmes auxiliaires : COMA, IQL, MADT, PBT.

3.6. SIREN avec conditionnement FiLM

Représentation neuronale implicite [2] à activations sinusoïdales et modulation linéaire par caractéristique (FiLM) :

$$\boldsymbol{h}_{\ell+1} = \sin\big(\omega_0\,(\boldsymbol{W}_\ell \boldsymbol{h}_\ell + \boldsymbol{b}_\ell)\big), \qquad \boldsymbol{h}_\ell \leftarrow \boldsymbol{\gamma}_\ell(\boldsymbol{\xi}) \odot \boldsymbol{h}_\ell + \boldsymbol{\beta}_\ell(\boldsymbol{\xi}). \tag{9}$$

Le choix $\omega_0 = 30$ correspond à la prescription spectrale de Sitzmann *et al.*. Avec 0,83M paramètres le modèle atteint un MAE de validation de $0{,}0098$ sur T_a normalisé.

3.7. DeepONet avec features de Fourier

Apprentissage d'opérateurs [3] :

$$T_a(k) = \big\langle \mathrm{branch}(\boldsymbol{\xi}),\ \ \mathrm{trunk}(\gamma(k))\big\rangle + b_0, \tag{10}$$

avec le plongement de Fourier $\gamma(k) = \big[\,k,\ \{\sin(2\pi w_i k), \cos(2\pi w_i k)\}_{i=1}^{16}\,\big]$, les pulsations w_i étant log-espacées jusqu'à $\omega_{\max} = 16$.

3.8. Régression spectrale de Chebyshev

Chaque branche est décomposée sur la base tronquée des polynômes de Chebyshev de première espèce :

$$T_a(k_{\mathrm{norm}}) = \sum_{n=0}^{N} c_n(\boldsymbol{\xi})\, T_n(k_{\mathrm{norm}}), \qquad N = 16, \tag{11}$$

avec $T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x)$. Un Transformer encodeur à 4 couches associe à $\boldsymbol{\xi}$ les coefficients $\{c_n\}_{n=0}^{16}$. Bien que globalement régulière, cette base polynomiale tronquée souffre du phénomène de Gibbs aux cusps de croisement de modes.

3.9. Multi-Mode Envelope SIREN ★

Conçu pour respecter la structure d'enveloppe de Floquet [Eq. (3)] : $M = 4$ modes SIREN partagent un encodeur de contexte et la sortie est leur enveloppe inférieure dure,

$$T_a(k, \boldsymbol{\xi}) \;=\; \min_{m=1,\dots,M} T_m(k, \boldsymbol{\xi}), \qquad T_m(k, \boldsymbol{\xi}) = f_m^{\mathrm{SIREN}}(k\,;\,\phi_{\mathrm{ctx}}(\boldsymbol{\xi})) + \beta_m, \tag{12}$$

avec biais de rupture de symétrie $\{\beta_m\}$. Le min dur est différentiable par morceaux : les gradients ne traversent que le mode actif, donc chaque T_m se spécialise sur la région paramétrique où il est le seuil le plus bas, exactement comme un mode propre de Floquet.

4. Apprentissage : MSE pondérée par les kinks et lissage sélectif

Loss. La MSE standard sous-pondère les rares échantillons proches d'un cusp. On utilise une MSE pondérée par les kinks

$$\mathcal{L}(\theta) = \frac{1}{BT} \sum_{b,t} w(t \mid T_a^{\texttt{vrai}}{}_b) \cdot \big(f_\theta(k_t, \boldsymbol{\xi}_b) - T_a^{\texttt{vrai}}{}_{b,t}\big)^2, \tag{13}$$

avec le poids par échantillon

$$w(t \mid T_a^{\texttt{vrai}}) = 1 + (\alpha - 1)\, \sigma\big(2(z_t - \tau)\big), \qquad z_t = \frac{|\,\Delta^2 T_a^{\texttt{vrai}}{}_t\,|}{\mathrm{std}_t\, |\Delta^2 T_a^{\texttt{vrai}}{}_t|}, \tag{14}$$

où Δ^2 est la différence finie seconde, σ la sigmoïde, $\alpha = 5$ et $\tau = 2$. Les points dont la différence seconde dépasse 2σ sont pondérés jusqu'à $5\times$, focalisant le gradient sur les cusps.

Lissage sélectif (post-traitement). Pour la visualisation, les prédictions sont lissées par un filtre de Savitzky-Golay hors des zones de kink. En définissant le masque doux $M(t) = \mathrm{box}_\nu\big(\sum_{k\in\mathcal{K}} \mathbb{1}_{[\,k-e,\,k+e\,]}(t)\big)$ sur l'ensemble des kinks $\mathcal{K}$ avec marge e, la courbe affichée est

$$\widetilde{T_a}(t) = M(t)\, T_a(t) + (1 - M(t))\, \big(\mathrm{savgol}\, T_a\big)(t). \tag{15}$$

Le masque préserve exactement les cusps tout en aplanissant les parasites dans les régions plates.

5. Résultats

Évaluation sur les 720 branches de combined_data.csv en unités physiques de T_a :

Modèle	MAE	RMSE	MAE zone-kink	MaxErr
Multi-Mode Envelope SIREN ★	**0,549**	1,10	**0,785**	26,7
SIREN + FiLM	0,897	1,55	1,30	30,1
DeepONet	1,34	2,52	2,10	48,0
Sparse-MoE-T + 3-SAC (réf. legacy)	1,31	-	-	-
Régression Chebyshev	2,53	7,27	3,33	182,9

L'architecture d'enveloppe maison bat toutes les baselines régulières ainsi que la pipeline historique multi-agents d'un facteur $\approx 2{,}4$, tout en ayant l'erreur la plus faible sur les zones de kink et la queue la plus courte (MaxErr).

6. Conclusion

Encoder la structure de croisement de modes de Floquet $T_a = \min_m T_m$ comme biais inductif architectural, combiné à une loss MSE pondérée par les kinks, donne un surrogate qui ajuste les courbes de stabilité marginale à mieux que un pour cent sur 720 branches. Cette recette s'applique à d'autres problèmes de stabilité par valeurs propres où la courbe seuil est l'enveloppe inférieure de modes en compétition.

Références

[1] M. Hayani Choujaa *et al.*, « Linear stability of an oscillatory Taylor-Couette flow of an Upper-Convected Maxwell fluid with counter-oscillating cylinders », *Phys. Fluids* **33**, 074105 (2021).

[2] V. Sitzmann, J.N.P. Martel, A.W. Bergman, D.B. Lindell, G. Wetzstein, « Implicit Neural Representations with Periodic Activation Functions », NeurIPS 2020.

[3] L. Lu, P. Jin, G. Pang, Z. Zhang, G.E. Karniadakis, « Learning nonlinear operators via DeepONet », *Nature Mach. Intell.* **3**, 218 (2021).

[4] Z. Li *et al.*, « Fourier Neural Operator for Parametric Partial Differential Equations », ICLR 2021.

[5] T. Haarnoja *et al.*, « Soft Actor-Critic », ICML 2018.

[6] C. Chi *et al.*, « Diffusion Policy: Visuomotor Policy Learning via Action Diffusion », RSS 2023.